地球物理データ解析レジュメ 1

2026 年 10 月 23 日

目次

1 授業概要 3
- 1.1 地球物理データ解析 (Data analysis in Geophysics) . . . 3
- 1.2 講義資料とスケジュール . . . 3

2 スペクトル解析 1 5
- 2.1 スペクトル解析の目的と基本概念 . . . 5
- 2.2 自己回帰過程 (Autoregressive processes) . . . 5
- 2.3 相関関数と共分散関数 . . . 7

3 フーリエ解析 9
- 3.1 フーリエ級数とフーリエ変換 . . . 9
- 3.2 パワースペクトルとパーセバルの定理 . . . 10
- 3.3 離散データにおける解析と諸問題 . . . 11

4 スペクトル解析 2 13
- 4.1 スペクトル解析の概要と 3 つの手法 . . . 13
- 4.2 直接法 (Direct method) . . . 13
- 4.3 ブラックマン-テューキー法 (Blackman-Tukey 法) . . . 15

5 クロススペクトル (Cross Spectrum) 17
- 5.1 クロススペクトルの基礎 . . . 17
- 5.2 複素成分と位相差 . . . 18
- 5.3 コヒーレンスと解析例 . . . 19

6 ウェーブレット解析 (Wavelet Analysis) 21
- 6.1 ウェーブレット解析の基礎 . . . 21
- 6.2 実データへの応用 . . . 21

7 時間フィルタリング (Time Filtering) 23
- 7.1 フィルターの基礎と種類 . . . 23
- 7.2 代表的なフィルタリング手法 . . . 23

8 主成分分析 26
- 8.1 モード展開の基礎 . . . 26
- 8.2 2 地点のケースにおける定式化 . . . 26
- 8.3 主成分分析 (PCA) の一般化 . . . 27
- 8.4 解析における工夫：重み付けと双対形式 . . . 28

8.5 結果の解釈と主成分分析の拡張 29

9 最大共分散分析 32

9.1 最大共分散分析 (MCA) の基本概念 32

9.2 モードの性質と寄与率 33

9.3 空間パターンの解釈と応用 34

1　授業概要

1.1　地球物理データ解析 (Data analysis in Geophysics)

Chap 3. Analysis without model assumptions

- 担当: 小坂優 (先端科学技術研究センター) / Yu Kosaka (Research Center for Advanced Science and Technology)
- **Email**: ykosaka@atmos.rcast.u-tokyo.ac.jp

1.1.1　参考書

- 松山洋・谷本陽一『実践! 気候データ解析』古今書院
- 伊藤久徳・見延庄士郎 (2010)『気象学と海洋物理学で用いられるデータ解析法』気象研究ノート第 221 号，日本気象学会
- von Storch, H. and Zwiers, F. W. (1999) *Statistical analysis in climate research*, Cambridge University Press
- 日野幹雄 (1977)『スペクトル解析』朝倉書店

まとめ

本講義では、特定のモデルを仮定しないデータ解析手法を学びます。特に気象学や海洋物理学分野で頻繁に用いられるスペクトル解析や主成分分析などの実践的な手法が中心となります。指定された参考書を手元に置いておくことで、数式や理論の理解がより深まります。

例え話による解説

データ解析において「モデルを仮定しない」とは、料理で例えると「特定のレシピ（モデル）の枠に当てはめず、目の前にある食材（データ）そのものの味や特徴を直接味わって調べる」ようなものです。参考書は、そのための「包丁の正しい使い方」や「味見のコツ」が詳しく書かれたマニュアルと言えます。

1.2　講義資料とスケジュール

1.2.1　講義資料 (Lecture notes)

毎回の授業前に UTOL からダウンロードし、必要に応じてご自身で印刷した上で持参してください。

まとめ

授業中の理解をスムーズにするため、事前に資料に目を通しておくことが推奨されます。UTOL のシステムを忘れずに確認する習慣をつけましょう。

例え話による解説

講義資料は「旅行のガイドブック」のようなものです。事前にダウンロードしてパラパラとでもめくっておけば、授業という「実際の旅行」で迷子にならず、今どこを走っていて、何が重要な見どころなのかがすぐに分かります。

1.2.2 スケジュール (Schedule)

- **10 月 2 日**: Spectrum analysis 1（スペクトル解析 1）
- **10 月 9 日**: Spectrum analysis 2（スペクトル解析 2）
- **10 月 16 日**: Principal component analysis（主成分分析）
- **10 月 23 日**: Maximum covariance analysis（最大共分散分析）

まとめ

10 月はスペクトル解析の基礎と応用から始まり、主成分分析、最大共分散分析といった多変量解析の手法へと段階的に進みます。各週の手法がどのように関連し、どのように発展していくのかを意識しながら受講しましょう。

例え話による解説

スケジュールを見ると、まずは「波の性質を見抜く（スペクトル解析）」技術を学び、次に「データ全体の特徴探し（主成分分析）」、最後に「複数のデータの関係性を見つける（最大共分散分析）」へとステップアップしていくのがわかります。自転車の補助輪を外していくように、少しずつ複雑な気候データを自力で扱えるようになっていきます。

2　スペクトル解析 1

2.1　スペクトル解析の目的と基本概念

2.1.1　物理空間とスペクトル空間

- 目的: 1 次元データ（時系列データなど）の周波数・波数空間（スペクトル空間）における特性を把握すること。
- 物理空間 **(Physical space)**: $z(t)$ または $z(x)$ （変数: t または x）
- 波数/振動数空間 **(Spectral space)**: $Z(f)$ または $Z(k)$ （実部 real、虚部 imaginary、変数: f または k）
- 相互変換:
  - フーリエ変換 (Fourier transform): 物理空間 $\rightarrow$ スペクトル空間
  - フーリエ逆変換 (Fourier inverse transform): スペクトル空間 $\rightarrow$ 物理空間
- パワースペクトル **(Power spectrum)**: $|Z(f)|^2$ または $|Z(k)|^2$ を f または k の関数として表現。

まとめ

フーリエ変換を用いて時間や空間の変動を周波数・波数の成分に分解することがスペクトル解析の基本です。パワースペクトルを見ることで、どの周期（周波数）の変動が卓越しているかを知ることができます。

例え話による解説

音で例えると、録音した音楽（物理空間のデータ）から、「どの楽器の音が、どのくらいの強さで鳴っているか（スペクトル空間）」を分解して調べるようなものです。パワースペクトルは、特定の楽器の音量がどれくらい大きいかを示すグラフになります。

2.2　自己回帰過程 (Autoregressive processes)

2.2.1　白色ノイズと赤色ノイズ

- **White noise (白色ノイズ)**: 「記憶のない（no memory）」正規確率変数の系列（$t' \neq t$ である任意の $x(t')$ と $x(t)$ は独立）。自己相関関数は以下のように定義されます。

$$r_{xx}(\tau) = \delta(\tau) = \begin{cases} 1 & (\tau = 0) \\ 0 & (\tau \neq 0) \end{cases}$$

- **Red noise (赤色ノイズ)**: 直前のステップ $(t-1)$ の値とランダムな外力（白色ノイズ）に依存する系列。あらかじめ平均 μ_x は x から引いておきます。

$$x(t) = rx(t-1) + \sigma_W \epsilon(t)$$

  - r: 1 ステップ遅れの自己相関（Lag-1 autocorrelation、記憶”memory” を表す）
  - σ_W: 外力の大きさ（Magnitude of forcing）
  - $\epsilon(t)$: 白色ノイズ

- **定常性の条件**: $|r| \leq 1$
  - $0 < r < 1$: 赤色ノイズ (Red noise)
  - $r = 0$: 白色ノイズ (White noise)

まとめ

白色ノイズは完全にランダムで過去の影響を受けないのに対し、赤色ノイズは直前の状態に依存する（記憶を持つ）ノイズです。気候などの地球物理データでは、赤色ノイズがバックグラウンドの変動として頻繁に現れます。

例え話による解説

白色ノイズが「毎回サイコロを振って出る目」だとすれば、赤色ノイズは「前日の天気が今日の天気に影響を与える」ように、過去の余韻が残る現象に似ています。風が吹いて海面が波立つとき、波の揺れがすぐには収まらない状態を想像してください。

2.2.2 赤色ノイズモデルのパラメータ推定

$x(t)$ から赤色ノイズモデルを推定する方法は以下の通りです。

- r **の推定**: 時系列データのラグ 1 の自己相関 $r_{xx}(1)$ として推定可能です。
- σ_W **の推定**: 赤色ノイズの分散 σ_r^2 を用いて次のように導出します。

$$\begin{aligned}\sigma_r^2 \equiv E[x^2(t)] &= E[r^2x^2(t-1)] + 2r\sigma_W E[x(t-1)\epsilon(t)] + \sigma_W^2 E[\epsilon^2(t)] \\ &= r^2\sigma_r^2 + \sigma_W^2\end{aligned}$$

$$\therefore \sigma_W^2 = \sigma_r^2(1-r^2)$$

（ここで σ_r^2 は時系列 $x(t)$ の分散としてデータから推定します）

まとめ

実際の観測データから赤色ノイズをモデル化する際、ラグ 1 の自己相関 (r) とデータの分散 (σ_r^2) を計算するだけで、ランダム外力の大きさ (σ_W) を逆算し、モデルを構築することができます。

例え話による解説

料理の味付けで例えると、完成した料理（観測データ）を食べて、「元々の素材の味（前の状態からの影響 r）」と「後から足したスパイス（ランダムな外力 σ_W）」の割合を逆算してレシピを復元する作業に似ています。

2.2.3 AR(p) 過程と AR(1) 過程

- 時系列の値が過去 p ステップの値およびランダム外力に依存する過程を p **次自己回帰過程** $(\mathrm{AR}(p))$ と呼びます。

$$x(t) = \alpha_0 + \sum_{k=1}^{p} \alpha_k x(t-k) + \sigma_W \epsilon(t)$$

- **AR(1) 過程 / 1 次のマルコフ過程 (First-order Markov process)**:
  - $0 < \alpha_1 < 1 \rightarrow$ 赤色ノイズと同じモデル。
  - 自己相関関数はラグ τ に対して指数関数的に減衰します: $r_{xx}(\tau) = \alpha_1^{\tau}$

まとめ

過去 p ステップの記憶を持つものを AR(p) 過程と呼びます。中でも過去 1 ステップのみに依存する AR(1) 過程（1 次のマルコフ過程）は、赤色ノイズと同義であり、自己相関が指数関数的に減衰するという重要な特徴を持っています。

例え話による解説

AR(p) は「過去 p 日分の出来事を引きずっている状態」です。対して AR(1) は「昨日のことしか直接影響しない状態」です。ただ、昨日の出来事は一昨日の出来事の影響を受けているため、結果として時間が経つにつれて徐々に記憶（自己相関）が薄れていく様子を表しています。

2.3 相関関数と共分散関数

2.3.1 連続時間の相関・共分散

$x(t)$ および $y(t)$ を考え、平均と標準偏差を以下とします。

$$\mu_x = E[x], \quad \sigma_x = \sqrt{E[(x-\mu_x)^2]}, \quad \mu_y = E[y], \quad \sigma_y = \sqrt{E[(y-\mu_y)^2]}$$

- (相互) 共分散関数:

$$v_{xy}(\tau) = E[(x(t)-\mu_x)(y(t+\tau)-\mu_y)]$$

- (相互) 相関関数:

$$r_{xy}(\tau) = \frac{v_{xy}(\tau)}{\sigma_x \sigma_y}$$

- 自己共分散関数:

$$v_{xx}(\tau) = E[(x(t)-\mu_x)(x(t+\tau)-\mu_x)]$$

（性質: $v_{xx}(\tau) = v_{xx}(-\tau)$）

- 自己相関関数:

$$r_{xx}(\tau) = \frac{v_{xx}(\tau)}{v_{xx}(0)}$$

（性質: $r_{xx}(\tau) = r_{xx}(-\tau), \quad r_{xx}(0) = 1$）

まとめ

理論的な枠組みでは、連続時間における期待値 (E) を用いて共分散や相関関数を定義します。自己共分散関数や自己相関関数は、ラグ τ について偶関数（左右対称）になるという数学的性質があります。

例え話による解説

2 つの波（データ）の「似ている度合い」を測る定規を作るための理論上の設計図のようなものです。自分自身の過去とどれくらい似ているか（自己相関）や、別のデータとどれくらい連動しているか（相互相関）を数式で厳密に定めています。

2.3.2 離散時系列の相関・共分散

有限長の離散時系列 x_n, y_n $(n = 1, 2, \ldots, N)$ を考えます。平均と標準偏差の推定量は以下の通りです。

$$\bar{x} = \frac{1}{N}\sum_{n=1}^{N} x_n, \quad s_x = \sqrt{\frac{1}{N-1}\sum_{n=1}^{N}(x_n - \bar{x})^2}$$

$$\bar{y} = \frac{1}{N}\sum_{n=1}^{N} y_n, \quad s_y = \sqrt{\frac{1}{N-1}\sum_{n=1}^{N}(y_n - \bar{y})^2}$$

- **(相互) 共分散関数:**

$$v_{xy}(\tau) = \frac{1}{N-\tau}\sum_{n=1}^{N-\tau}(x_n - \bar{x})(y_{n+\tau} - \bar{y})$$

（通常は $\bar{x} = \frac{1}{N-\tau}\sum_{n=1}^{N-\tau} x_n, \quad \bar{y} = \frac{1}{N-\tau}\sum_{n=1}^{N-\tau} y_{n+\tau}$ を用います）

- **(相互) 相関関数:**

$$r_{xy}(\tau) = \frac{v_{xy}(\tau)}{s'_x s'_y}$$

（s'_x は $s'_x = \sqrt{\frac{1}{N-\tau}\sum_{n=1}^{N-\tau}(x_n - \bar{x})^2}$ または $s'_x = \sqrt{\frac{1}{N}\sum_{n=1}^{N}(x_n - \bar{x})^2}$ のいずれかを採用）

- **自己共分散関数:**

$$v_{xx}(\tau) = \frac{1}{N-\tau}\sum_{n=1}^{N-\tau}(x_n - \bar{x})(x_{n+\tau} - \bar{x})$$

- **自己相関関数:**

$$r_{xx}(\tau) = \frac{v_{xx}(\tau)}{v_{xx}(0)}$$

まとめ

実際のデータ解析では有限の離散データ（サンプリングされたデータ）を扱うため、総和を用いた推定式を使用します。ラグ τ が大きくなると計算に使えるデータペアの数 $(N - \tau)$ が減少し、推定の精度が落ちる点に注意が必要です。

例え話による解説

理論上の設計図（連続時間）を、実際のデジカメの画素（離散データ）に当てはめて計算するようなものです。写真をずらして重ね合わせる（ラグ τ を増やす）とき、ずらしすぎると重なる部分（サンプル数）が少なくなって画質（精度）が落ちてしまうのと同じ原理です。

3　フーリエ解析

3.1　フーリエ級数とフーリエ変換

3.1.1　フーリエ級数 (Fourier series)

周期 T の時系列 $x(t)$ は、三角関数を用いて以下のように展開できます。

$$x(t) = \frac{a_0}{2} + \sum_{k=1}^{\infty} \left(a_k \cos \frac{2\pi kt}{T} + b_k \sin \frac{2\pi kt}{T} \right)$$

$$a_k = \frac{2}{T} \int_0^T x(t) \cos \frac{2\pi kt}{T} dt, \quad b_k = \frac{2}{T} \int_0^T x(t) \sin \frac{2\pi kt}{T} dt$$

複素形式 (Complex form) オイラーの公式を用いることで、より簡潔な複素形式で表現できます。

$$x(t) = \sum_{k=-\infty}^{\infty} c_k e^{\frac{2\pi ikt}{T}}$$

$$c_k = \frac{1}{T} \int_0^T x(t) e^{-\frac{2\pi ikt}{T}} dt = \begin{cases} \frac{a_k - ib_k}{2} & (k \geq 0) \\ \frac{a_{-k} + ib_{-k}}{2} & (k < 0) \end{cases}$$

まとめ

フーリエ級数は、「周期的なデータ」を様々な周期を持つサイン波とコサイン波の足し合わせとして表現する手法です。計算をシンプルにするために、数学や物理では複素形式（$e^{i\theta}$）が好んで使われます。

例え話による解説

複雑な形をした波を、「基本の波」「2 倍の速さの波」「3 倍の速さの波」……というように、綺麗な波の部品（パーツ）に分解する作業です。a_k や b_k は、それぞれの部品が「どれくらいの強さで含まれているか」を示す取扱説明書のようなものです。

3.1.2　フーリエ変換 (Fourier transform)

フーリエ級数において周期 $T \to \infty$ の極限を取ることで、非周期的な関数へも適用できるように拡張したものがフーリエ変換です。

$$x(t) = \int_{-\infty}^{\infty} X(f) e^{2\pi ift} df$$

$$X(f) = \int_{-\infty}^{\infty} x(t) e^{-2\pi ift} dt$$

（※ 表記ルール: 時系列データは小文字の x、そのフーリエ変換は大文字の X で表します）

まとめ

フーリエ変換は、特定の周期を持たない（あるいは周期が無限大の）一般的なデータに対してスペクトル解析を行うための基礎となる強力なツールです。

例え話による解説

フーリエ級数が「一定の長さを繰り返すループ音楽」を分解するものだとすれば、フーリエ変換は「一度しか演奏されない一発勝負のライブ音源」に含まれるすべての音の成分を解析するようなものです。

3.2 パワースペクトルとパーセバルの定理

3.2.1 パワースペクトルとエネルギー保存

- **振幅**: 振動数 f における振幅は $|X(f)|$ または $\sqrt{a_f^2 + b_f^2}$。
- **パワースペクトル**: 振幅の 2 乗である $|X(f)|^2$ または $a_f^2 + b_f^2$。
- **パーセバルの定理 (Parseval's theorem)**:

$$\int_{-\infty}^{\infty} [x(t)]^2 dt = \int_{-\infty}^{\infty} |X(f)|^2 df$$

これは「物理空間におけるデータの分散（エネルギー）」と「スペクトル空間におけるエネルギーの総和」が保存される（等しい）ことを示しています。

まとめ

パーセバルの定理は、データ解析において非常に重要です。時間領域で計算した変動の大きさ（分散）が、周波数領域で計算したパワースペクトルの総和と一致するという保証を与えてくれます。

例え話による解説

ホールケーキを丸ごと食べる（時間領域のエネルギー）のと、8 等分に切り分けてから全部食べる（周波数ごとのエネルギーの足し合わせ）のでは、最終的に胃の中に入るカロリー（総エネルギー）は全く同じになる、という法則です。

3.2.2 パワースペクトル密度と片側・両側スペクトル

無限長の積分ではパーセバルの定理の左辺が発散するため、単位時間あたりのエネルギーである **パワースペクトル密度 (PSD)** を定義します。

$$P(f) \equiv \lim_{T\to\infty} \frac{|X(f)|^2}{T} = \lim_{\Delta f\to 0} |X(f)|^2 \Delta f$$

一般に「パワースペクトル」と呼ばれるものは、この PSD を指すことが多くなります。

片側 vs 両側スペクトル時系列 $x(t)$ が実数の場合、スペクトルは正と負の振動数で対称 ($P(f) = P(-f)$) になります。そのため、正の周波数成分のみを 2 倍にして扱う **片側スペクトル (One-sided spectrum)** が実用的です。

$$G(f) \equiv 2P(f) \quad (f \geq 0)$$

まとめ

実際の観測データは実数であるため、パワースペクトルはマイナスの周波数とプラスの周波数で対称になります。無駄を省くために、プラスの周波数だけを見て値を 2 倍にする「片側スペクトル」がデータ解析の現場で広く使われます。

例え話による解説

鏡に映った自分の顔（両側スペクトル）を見るようなものです。右半分（プラスの周波数）と左半分（マイナスの周波数）が同じ形をしているなら、わざわざ両方記録しなくても、右半分のデータを 2 倍にすれば顔全体の面積（エネルギー）が計算できるよね、という合理的な考え方です。

3.3 離散データにおける解析と諸問題

3.3.1 離散フーリエ変換とナイキスト振動数

有限のサンプリング間隔 Δt とデータ長 $T = N\Delta t$ を持つ実離散時系列 $\{x(t_n)\}$ に対する解析です。

$$x(t_n) = \sum_{k=-M}^{M} X(f_k) e^{2\pi i f_k t_n}, \quad f_k = \frac{k}{T}$$

$$X(f_k) = \frac{\Delta t}{T} \sum_{n=1}^{N} x(t_n) e^{-2\pi i f_k t_n}$$

ナイキスト振動数 (Nyquist frequency) 分解可能な最高振動数（捉えることができる最も短い周期）はサンプリング間隔によって決まります。

$$f_N \equiv \frac{1}{2\Delta t}$$

まとめ

ナイキスト振動数は、観測データのサンプリング間隔 Δt によって決まる「測れる波の限界」です。Δt ごとにデータを取る場合、最低でも 1 波長につき 2 回のデータ点がないと波の形を認識できないため、この限界値が生じます。

例え話による解説

パラパラ漫画を作る時、1 秒間に 2 枚しか絵を描かない（サンプリング間隔が粗い）と、1 秒間に 3 回羽ばたく鳥の動きは描けません。ナイキスト振動数は、「このパラパラ漫画の枚数で、どこまで速い動きをごまかさずに表現できるか」の限界スピードのことです。

3.3.2 ピリオドグラムとその欠点

離散データからパワースペクトルを推定したものを **ピリオドグラム (Periodogram)** と呼びます。

$$P(f_k) \equiv \frac{1}{N\Delta t} |X(f_k)|^2 \quad (-f_N < f_k \leq f_N)$$

大きな誤差の発生単純に計算したピリオドグラムは、統計的に推定誤差が非常に大きくなります（分散が自由度 2 の χ^2 分布に従うため）。重要な点は、**データ長 N をどれだけ増やしても、この誤差（激しい揺らぎ）は小さくならない**ということです。

まとめ

生のデータからそのままフーリエ変換して求めたスペクトル（ピリオドグラム）は、ギザギザが激しく、そのままではノイズと真の信号の区別がつきません。データの長さを増やしてもギザギザは細かくなるだけで、縦方向のブレは改善しないため、後の章で学ぶ「平滑化（スムージング）」という処理が必須になります。

例え話による解説

ピリオドグラムの誤差は、双眼鏡の倍率をひたすら上げるようなものです。倍率（データ長 N）を上げても、視界が細かく（周波数分解能が向上）なるだけで、手ブレ（推定誤差）は全く直りません。手ブレをなくすには、後から画像をぼかして滑らかにする（平滑化する）別の工夫が必要です。

3.3.3 エイリアシングとスペクトルの漏れ

データ解析において注意すべき特有の現象です。

- **エイリアシング (Aliasing)**: ナイキスト周波数を超える高い周波数の波が、サンプリングの粗さによって見かけ上低い周波数の波として誤認されてしまう現象。スペクトルが f_N で折り返されてしまいます。
- **ギブス現象 (Gibbs phenomenon)**: データに不連続な部分や急激な変化がある場合、フーリエ変換で再現しようとすると、その境界付近で波が激しく振動してはみ出してしまう（オーバーシュート）現象。
- **スペクトルの漏れ (Spectral leakage)**: 有限の長さでデータをスパッと切り出す（矩形窓を掛ける）ことで、本来は 1 本のきれいな線になるはずのスペクトルが周囲の周波数へと滲み出してしまう現象。たたみ込み定理により、矩形窓のフーリエ変換の影響が入力データに混ざることが原因と説明されます。

まとめ

エイリアシングは「サンプリング間隔が粗すぎる」こと、スペクトルの漏れは「データを途中でぶつ切りにする」ことによって起こるアーティファクト（偽の信号）です。これらを理解しておくことで、結果の誤解釈を防ぐことができます。

例え話による解説

エイリアシングは、車のタイヤが高速で回転している時に、テレビの映像だと逆回転しているように見える錯覚現象と同じです（コマ数が足りないため）。スペクトルの漏れは、スポットライトの光を小さな丸い穴から通そうとした時、縁から光がぼんやりと漏れ出してしまう状態に似ています。

4　スペクトル解析 2

4.1　スペクトル解析の概要と 3 つの手法

ピリオドグラム法の課題（大きな推定誤差、スペクトルの漏れ）を克服するために、主に以下の 3 つの手法が用いられます。

- **直接法 (Direct method / FFT 法 / Cooley-Tukey 法)**
  - ピリオドグラムを平滑化する手法。
  - ノンパラメトリック（モデル仮定なし）。
  - 高速であり、FFT（高速フーリエ変換）開発以降もっとも広く普及しています。
- **ブラックマン-テューキー法 (Blackman-Tukey 法, B-T 法)**
  - 自己共分散関数のフーリエ変換に基づく手法。
  - ノンパラメトリック。
  - 計算は遅いが、データに欠測値が存在する場合に有用です。
- **最大エントロピー法 (Maximum entropy method, MEM)**
  - パラメトリック（AR(p) モデルを仮定）。
  - 周波数分解能が非常に高いのが特徴。
  - ただし、誤差推定が困難（本講義では深く扱いません）。

まとめ

解析対象のデータ長が十分で欠測がない場合は「直接法（FFT）」が標準です。欠測がある場合は「B-T 法」、短いデータから高い分解能で周期を見つけたい場合は「MEM」というように使い分けます。

例え話による解説

直接法は「大量の食材をミキサー（FFT）で一気に処理する現代的な調理法」。B-T 法は「手作業で丁寧に下ごしらえ（自己共分散）してから煮込む伝統的な調理法（時間はかかるが虫食い野菜でも対応可能）」。MEM は「限られた食材から、AI（モデル）を使って最もあり得そうな味を予測する分子ガストロノミー」のようなものです。

4.2　直接法 (Direct method)

4.2.1　平滑化 (Smoothing) とテーパリング (Tapering)

FFT を用いて変換を行った後、以下の処理を施して誤差と漏れを抑えます。

- **平滑化 (Smoothing)**: 推定分散を抑える（エラーバーを小さくする）ために行います。
  - **移動平均**: 周辺の周波数帯で平均をとる。n 点移動平均の場合、自由度は $2n$ となります。
  - **セグメント分割**: 時系列を複数のセグメントに分割し、それぞれのスペクトルを平均する。重複を許す（50% オーバーラップなど）切り出しが効率的です。
- **テーパリング (Tapering)**: スペクトルの漏れを抑えるために行います。

– 時系列の両端を滑らかに 0 に落とす窓関数（Cos20, Hanning, Hamming など）を掛けます。※ 必ず**事前に平均値を差し引く**必要があります。
– テーパリングを行うと時系列全体のエネルギーが減少するため、フーリエ変換後にスペクトルを再スケーリング（スケールバック補正）する必要があります。

まとめ

平滑化は「周波数分解能（細かさ）」を犠牲にして「統計的信頼性（縦軸の正確さ）」を上げるトレードオフの作業です。テーパリングも「メインローブの幅が広がる」という代償を払って「サイドローブへの漏れ」を防ぐトレードオフです。

例え話による解説

平滑化は「写真の画素数を落としてノイズを消し、滑らかにする画像補正」です。テーパリングは「パノラマ写真をつなぎ合わせる時、端っこが不自然にならないように境界を徐々に透明にぼかす（フェードアウトさせる）処理」に似ています。

4.2.2 誤差推定と有意なピークの検出

- **信頼区間の導出**: 平滑化後の自由度 ν（n 点移動平均なら $\nu = 2n$）に基づき、スペクトル推定値 $\hat{G}(f)$ は χ^2（カイ二乗）分布を用いた以下の $100(1-\alpha)\%$ 信頼区間に収まります。

$$\frac{\nu G(f)}{\chi^2(\nu, 1-\frac{\alpha}{2})} \leq \hat{G}(f) \leq \frac{\nu G(f)}{\chi^2(\nu, \frac{\alpha}{2})}$$

- **対数表示 (デシベル)**: 対数をとることで信頼区間の幅（エラーバーの長さ）が一定になるため、グラフ上で比較しやすくなります。
- **有意性の検定**: 気候データなどでは、**赤色ノイズスペクトル $G_r(f)$ に対する有意性**が検定されます。推定したピークが赤色ノイズの信頼区間上限（棄却限界）を超えていれば、「意味のある周期変動」とみなせます。

まとめ

気候データには赤色ノイズ（バックグラウンドの揺らぎ）が常に存在します。単にスペクトルが山になっているだけでなく、その山が「赤色ノイズの偶然の揺らぎ（エラーバーの範囲）」を明確に突き抜けているかどうかを確認することが最も重要です。

例え話による解説

クラスのテストの平均点がたまたま高かったのか、それとも本当に実力が上がったのかを判断するようなものです。赤色ノイズは「実力に関係ない偶然のブレ幅（たまたま勘が当たった等）」です。ピークが棄却限界を超えるということは、「これは偶然じゃ説明がつかないほど突出している（実力だ）!」と認定されることを意味します。

4.2.3 直接法の手順 (Recipe)

スペクトル解析を行う際の具体的なステップは以下の通りです。

1. 平均値の除去 (Remove average)
2. 事前フィルタリング (Pre-filtering) ※ 必要に応じて
3. 白色化 (Pre-whitening) ※ 必要に応じて赤色ノイズ成分を除去・後で復元
4. セグメントへの分割 (Divide into segments)
5. テーパリング (Tapering)
6. ゼロ埋め (Zero-padding) ※FFT 高速化のため
7. フーリエ変換による粗スペクトルの算出
8. 移動平均による平滑化 (Moving average)
9. セグメント間の平均 (Average the spectra)
10. テーパーに応じた補正 (Rescaling)
11. 自由度に基づく誤差・信頼区間の推定 (Estimate errors)

まとめ

この 11 ステップが直接法を用いたスペクトル解析の「標準的なレシピ」です。プログラミングで解析を行う際は、この順番を間違えないように（特にテーパリング前の平均値除去など）実装することが重要です。

例え話による解説

料理のフルコースを作る手順書です。「野菜を洗う（平均値除去）」「不要な部分を切る（フィルタリング）」「一口サイズに分ける（セグメント分割）」「味付けを馴染ませる（テーパリング）」……というように、順番を間違えると美味しいスペクトル（正しい解析結果）は完成しません。

4.3 ブラックマン-テューキー法 (Blackman-Tukey 法)

4.3.1 ウィーナー・ヒンチンの定理

B-T 法の数学的基盤となる重要な定理です。自己共分散関数 $v_{xx}(\tau)$ のフーリエ変換がパワースペクトル $P(f)$ となり、逆もまた成り立ちます。

$$v_{xx}(\tau) = \int_{-\infty}^{\infty} P(f) e^{2\pi i f \tau} df = 2\int_{0}^{\infty} P(f)\cos(2\pi f\tau) df$$

$$P(f) = \int_{-\infty}^{\infty} v_{xx}(\tau) e^{-2\pi i f \tau} d\tau = 2\int_{0}^{\infty} v_{xx}(\tau)\cos(2\pi f\tau) d\tau$$

これにより、データを直接フーリエ変換しなくても、自己共分散関数を経由してスペクトルを計算できることが保証されます。

まとめ

ウィーナー・ヒンチンの定理は、「時間領域におけるデータの自己相関の強さ」と「周波数領域におけるエネルギー（パワースペクトル）」が表裏一体の関係にあることを示す、データ解析における最も美しい定理の一つです。

例え話による解説

「直接顔の絵を描く（直接法）」のと、「顔の形をとったデスマスク（自己共分散）を作ってから、それに色を塗って顔を復元する（B-T 法）」のが、最終的に同じ顔（パワースペクトル）になるという魔法の法則です。

4.3.2　離散時系列への適用とラグ打ち切り

離散データに対しては、最大ラグ M までの自己共分散 $v_{xx}(m)$ を計算し、それをフーリエ変換（余弦項の級数）することでスペクトル $G(k)$ を近似します。

$$a_k = \frac{v_{xx}(0)}{M} + \frac{2}{M}\sum_{m=1}^{M-1} v_{xx}(m)\cos\frac{\pi k m}{M} + \frac{v_{xx}(M)}{M}(-1)^k$$

$$G(k) = a_k/\Delta f = 2a_k M\Delta t$$

ラグ打ち切りの影響計算量を減らす（またはデータ不足のため）ラグを M で打ち切る行為は、自己共分散関数に矩形窓を掛けることと同じです。これによりギブス現象が発生し、スペクトルが漏れてしまうため、ここでも窓関数による抑制（テーパリングに相当する処理）が重要になります。

まとめ

B-T 法でも直接法と同様に「どこかでデータをスパッと切る」ことによる弊害（スペクトルの漏れ）が生じます。直接法では「時系列データ」に窓を掛けますが、B-T 法では「自己共分散関数」に窓を掛けるという違いがあります。

例え話による解説

ラグの打ち切りは、犯人の足跡を追跡していて「ここまでしか足跡がないから、ここから先はなかったことにしよう」とスパッと捜査を打ち切るようなものです。急に打ち切ると、そこまでの推理結果（スペクトル）に矛盾やノイズ（漏れ）が生じてしまうため、徐々にフェードアウトさせる配慮が必要です。

5　クロススペクトル (Cross Spectrum)

5.1　クロススペクトルの基礎

5.1.1　定義と数式表現

単一の時系列データの周波数特性を表すパワースペクトルに対し、2 つの異なる時系列データ $x(t), y(t)$ の周波数領域における関係性を表すものが**クロススペクトル**です。パワースペクトル $P(f)$ とクロススペクトル $C_{xy}(f)$ は以下のように定義されます（$X(f), Y(f)$ はそれぞれ $x(t), y(t)$ のフーリエ変換）。

$$P(f) = \lim_{T\to\infty} \frac{1}{T}[X^*(f)X(f)]$$
$$C_{xy}(f) = \lim_{T\to\infty} \frac{1}{T}[X^*(f)Y(f)]$$

あるいは等価的に、相互共分散関数 $v_{xy}(\tau)$ を用いて次のように書くこともできます。

$$C_{xy}(f) = \int_{-\infty}^{\infty} v_{xy}(\tau)e^{-2\pi i f\tau}d\tau$$

x と y がともに実数の場合、$C_{xy}(f) = C_{xy}^*(-f)$ が成り立つため、片側スペクトル $G_{xy}(f) \equiv 2C_{xy}(f)$ $(f \geq 0)$ が用いられます。

離散時系列 $x(t_n), y(t_n)$ の場合、平滑化前のクロススペクトルは $C_{xy}(f_k) = \frac{1}{N\Delta t}[X^*(f_k)Y(f_k)]$ となりますが、これには**必ず平滑化（移動平均やセグメント分割）を適用しなければなりません**。または、Blackman-Tukey (B-T) 法を用いて $v_{xy}(\tau_m)$ のフーリエ変換として計算します。

まとめ

クロススペクトルは、2 つのデータセット間において、どの周波数帯で強い関係性（相関）があるかを示す指標です。実際のデータ計算時には、ノイズを減らし有意な結果を得るために「平滑化」の処理が必須となります。

例え話による解説

2 人の歌手（2 つのデータ）の歌声を分析するようなものです。パワースペクトルが「それぞれの歌手がどの音程を強く出しているか」を見るのに対し、クロススペクトルは「2 人がどの音程で綺麗にハモっているか（連動しているか）」を周波数ごとに探し出す分析手法です。

5.1.2　ウィーナー・ヒンチンの関係式の導出

クロススペクトルと相互共分散関数はフーリエ変換のペア（ウィーナー・ヒンチンの定理）となっており、以下の関係が成り立ちます。

$$v_{xy}(\tau) = \int_{-\infty}^{\infty} C_{xy}(f)e^{2\pi i f\tau}df$$

【証明】

$$
\begin{aligned}
v_{xy}(\tau) &= \lim_{T\to\infty} \frac{1}{T} \int_{-T/2}^{T/2} x(t)y(t+\tau)dt \\
&= \lim_{T\to\infty} \frac{1}{T} \int_{-T/2}^{T/2} x(t) \left[\int_{-\infty}^{\infty} Y(f)e^{2\pi i f(t+\tau)} df \right] dt \\
&= \lim_{T\to\infty} \frac{1}{T} \int_{-\infty}^{\infty} Y(f)e^{2\pi i f\tau} \left[\int_{-T/2}^{T/2} x(t)e^{-2\pi i f t} dt \right]^* df \quad (※ \text{積分順序の交換}) \\
&= \lim_{T\to\infty} \frac{1}{T} \int_{-\infty}^{\infty} Y(f)X^*(f)e^{2\pi i f\tau} df \\
&= \int_{-\infty}^{\infty} C_{xy}(f)e^{2\pi i f\tau} df
\end{aligned}
$$

まとめ

相互共分散関数（時間的なズレに基づく関係性）とクロススペクトル（周波数ごとの関係性）は、フーリエ変換を介して互いに完全に変換可能な、表裏一体の数学的関係にあります。

例え話による解説

「時間的なズレ」という視点と、「波の成分（周波数）」という視点が、数学の魔法の鏡（フーリエ変換）を通してお互いに映し出されている様子を示しています。時間を基準に測っても、波を基準に測っても、2 つのデータの本質的な関係性は失われません。

5.2 複素成分と位相差

5.2.1 コスペクトルと求積スペクトル

クロススペクトル $C_{xy}(f_k)$ は一般に**複素数**であり、実部と虚部に分けることができます。

$$C_{xy}(f_k) = K_{xy}(f_k) + iQ_{xy}(f_k)$$

- **実部 (K_{xy})**: コスペクトル (Co-spectrum)。偶関数であり、同位相の成分を表します。
- **虚部 (Q_{xy})**: 求積スペクトル (Quadrature spectrum)。奇関数であり、90 度位相がずれた成分を表します。

これを極形式で表現すると以下のようになります。

$$C_{xy}(f_k) = |C_{xy}(f_k)|e^{i\varphi_{xy}(f_k)}$$

ここで $\varphi_{xy}(f_k)$ は、振動数 f_k における $x(t)$ と $y(t)$ の**位相差 (phase difference)** を表します。

まとめ

クロススペクトルは複素数であるため、「強さ（振幅）」だけでなく「タイミングのズレ（位相差）」も同時に計算できます。実部はタイミングが合っている部分、虚部はタイミングがズレている部分を抽出したものです。

例え話による解説

2 人が同じ曲を歌っているとき、「全く同じタイミングで歌っている部分（コスペクトル）」と「一方が一拍遅れて追いかけるように歌っている部分（求積スペクトル）」に分けて評価する仕組みです。極形式を使えば、「全体としてどちらがどれくらい遅れて歌っているか（位相差）」が角度として直接計算できます。

5.3 コヒーレンスと解析例

5.3.1 2 乗コヒーレンスの定義と性質

特定の周波数における 2 変数間の相関の強さを示す指標として、**2 乗コヒーレンス (Squared coherence)**（単に「コヒーレンス」とも）が用いられます。

$$\gamma_{xy}^2(f_k) = \frac{|G_{xy}(f_k)|^2}{G_{xx}(f_k)G_{yy}(f_k)} = \frac{|C_{xy}(f_k)|^2}{P_{xx}(f_k)P_{yy}(f_k)}$$

この値は $0 \leq |\gamma_{xy}(f_k)| \leq 1$ の範囲をとります。通常の相関係数の二乗 $r_{xy}^2 = v_{xy}^2/(\sigma_x^2\sigma_y^2)$ に対応するものですが、コヒーレンスは「振動数 f_k 付近における位相差を許容した相関」を表します（1 乗コヒーレンスとして位相情報 φ_{xy} を含めて表すこともあります）。

注意すべき点として、平滑化を行わない素のピリオドグラム同士から計算すると、位相差を許容する都合上、どの周波数でも相関が恒等的に 1 になってしまいます。そのため、有意なコヒーレンスを得るには**平滑化または B-T 法が必須**です。

まとめ

2 乗コヒーレンスは、周波数帯ごとの「相関係数」のようなものです（0〜1 の値をとる）。単純な相関係数とは異なり、タイミング（位相）がズレていても波形が連動していれば高い値を示します。ただし計算時の平滑化を怠ると、すべて 1 になってしまうため注意が必要です。

例え話による解説

ラジオのチューニングメーターに例えられます。特定の周波数（チャンネル）に合わせたとき、2 つの放送局が「全く同じ番組」を流しているか（コヒーレンス 1）、それとも「全く無関係な番組」を流しているか（コヒーレンス 0）を測るメーターです。片方の放送が数秒遅延していても（位相差）、同じ番組であればメーターは 1 を指します。

5.3.2 解析例

実際の気候研究におけるクロススペクトルおよびコヒーレンス解析の例として、以下の 2 つが挙げられます。

1. **Xie, Kosaka & Okumura (2016)**: モデルシミュレーションを用いて、全球平均地上気温と大気上端の正味放射量の 2 乗コヒーレンスおよび位相差を解析し、気候システムのエネルギーバランスの連動性を評価しています。
2. **Lin, Min & Ramaswamy (2015)**: 気候モデルシミュレーションにおける熱帯平均地表面温度と、成層圏の大気循環であるブリューワー・ドブソン循環（浅い循環・深い循環）の強さの間の 2 乗コヒー

レンスを調べ、地表と上空の力学的な結びつきを明らかにしています。

まとめ

実際の研究現場では、地球全体の気温と宇宙に逃げる熱のバランスや、地表の温度と遠く離れた上空の大気循環など、一見異なる現象が特定の周期でどのように連動しているかを証明するためにコヒーレンス解析が使われます。

例え話による解説

「地球の体温（気温）」と「地球の呼吸（大気循環や放射）」という、別々の方法で測られた 2 つの健康診断データが、実は特定の周期（たとえば 10 年周期など）でピタリと連動して変化していることを証明する「レントゲン写真」のような役割を果たします。

6　ウェーブレット解析 (Wavelet Analysis)

6.1　ウェーブレット解析の基礎

6.1.1　局所スペクトルと代表的な関数

通常のフーリエ変換は「時系列全体」に基づいてスペクトルを計算するため、「いつ、どの周波数の波が強かったか」という時間的な変化を捉えることができません。これを克服するのが**ウェーブレット解析**です。

正弦波（サイン波・コサイン波）の代わりに、空間的に局在した「ウェーブレット関数」を基底関数として使用することで、時間に伴うスペクトルの変調（Modulations）を捉える**局所スペクトル (Local spectrum)** を得ることができます。また、ウェーブレット関数自体が両端でゼロに収束する形をしているため、事前のテーパリング（窓関数掛け）が不要であるという利点もあります。

代表的なウェーブレット関数には以下のようなものがあります。

- **モルレー (Morlet) ウェーブレット**: 平面波にガウス窓を掛けたもので、地球科学の分野で頻出します。

$$\psi(t) = \pi^{-1/4} e^{i\omega_0 t} e^{-t^2/2} \quad (\text{例: } \omega_0 = 5)$$

- **メキシカンハット (Mexican hat) ウェーブレット**
- **ハール (Haar) ウェーブレット**

※ 文献参考: Kumar P. & Foufoula-Georgiou, E. (1997) "Wavelet analysis for geophysical applications" *Reviews of Geophysics*, 35, 385-412.

6.2　実データへの応用

6.2.1　エルニーニョ解析と影響円錐 (COI)

Torrence & Compo (1998, BAMS) による Nino3 海面水温 (SST) 偏差（1870〜2000 年）の解析が代表的な実例です。横軸に時間（year）、縦軸にスケールまたはフーリエ周期（years）をとって結果を描画することで、2〜7 年周期のエルニーニョ・南方振動 (ENSO) の活動強度が、年代によってどのように変化しているかが明瞭に可視化されます。

ただし解析結果の両端付近（網掛け部分）は、データの端切れの影響（**Edge effects**）を受けるため、**影響円錐 (Cone of Influence, COI)** と呼ばれる信頼性の低い領域として扱われます。

まとめ

気候データ（エルニーニョなど）の解析では、横軸に時間、縦軸に周期（スケール）をとったカラーマップ（スカラグラム）がよく描かれます。端の部分は「影響円錐 (Cone of Influence, COI)」と呼ばれ、データの端切れによるエッジ効果で信頼性が落ちる領域として網掛け処理されるのが一般的です。

例え話による解説

音楽の録音データを分析する状況を想像してみてください。フーリエ変換は「曲全体を通して、どの高さの音が何回使われたか」を教えてくれますが、「いつその音が鳴ったか」は分かりません。一方、ウェーブレット変換はまさに「楽譜」のようなもので、「どのタイミングで、どの高さの音が鳴っているか」を二次元のマップで教えてくれます。途中で急に高音のノイズが入ったり、リズムが変わったりする様子（時間的な変化）を捉えるのに最適な手法です。

7　時間フィルタリング (Time Filtering)

7.1　フィルターの基礎と種類

7.1.1　ローパス・ハイパスと応答関数

時間フィルタリングとは、時系列データから特定の周波数成分（周期）を抽出・除去する操作です。代表的なものに、高周波成分を抑えて低周波成分を抽出する**低周波フィルター (Low-pass filter)** と、その逆の**高周波フィルター (High-pass filter)** があります。

元のシグナル $x(t)$ にフィルターをかけた後のシグナル $y(t)$ は、**応答関数（伝達関数）** $B(f)$ を用いて以下のように表されます。

$$x(t) = e^{2\pi i f t} \xrightarrow{\text{filter}} y(t) = B(f)e^{2\pi i f t}$$

$B(f)$ は複素数になり得ますが、虚数成分を持つと波のタイミング（位相）がずれてしまうため、優れたフィルターは $B(f)$ **が実数かつ正**であることが望まれます。また、フィルターの効果が半減する（$|B(f)|^2 = 0.5$ となる）振動数 f_c を**カットオフ振動数**と呼びます。

線形フィルター（$\widetilde{x+y} = \tilde{x} + \tilde{y}$）を前提とした場合、ローパスとハイパスを組み合わせることで以下のようなフィルターを構成できます。

- **帯域通過フィルター (Band-pass filter)**: カットオフ f_L のローパス＋カットオフ f_H のハイパス（$f_L > f_H$）。特定の周波数帯だけを通す。
- **帯域阻止フィルター (Band-stop / Notch filter)**: 上記と同様の構成で $f_L < f_H$ としたもの。特定の周波数帯だけを遮断する。

まとめ

フィルターを通すことで、データに含まれる様々な周期の波の中から「10 年周期の変動だけ見たい」「年ごとの細かいノイズを消したい」といった目的に合わせた成分だけを取り出すことができます。

例え話による解説

オーディオのイコライザー（音質調整）と同じ仕組みです。「低音（低周波）を強調して、高音（高周波）のシャリシャリしたノイズをカットする」のがローパスフィルター、「ボーカルの音域（特定の周波数帯）だけを抽出する」のがバンドパスフィルターに相当します。

7.2　代表的なフィルタリング手法

7.2.1　移動平均と二項フィルター

もっとも単純なローパスフィルターが n **点移動平均 (Moving average, Boxcar filter)** です。n が奇数の場合、計算式は以下のようになります。

$$y_i = \frac{1}{n} \sum_{j=-\frac{n-1}{2}}^{\frac{n-1}{2}} x_{i+j}$$

系列が循環的でない限り、端点のデータを計算できないため、最初と最後の $(n-1)/2$ 点ずつは**欠測 (missing)** となります。より一般的には、重み w_j を用いた加重平均 $y_i = \sum_j w_j x_{i+j}$ として定義されます（偶数 n の場合は両端の重みを調整して計算します）。

移動平均の重みを一定（$1/n$）にするのではなく、**二項係数**を用いて中央の重みを大きくし、端に向かってなだらかに小さくしたものが**二項フィルター (Binomial filters)** です（$\sum_j w_j = 1$ に正規化）。

- 1 次: $\left\{\frac{1}{4}, \frac{1}{2}, \frac{1}{4}\right\}$ （いわゆる「1-2-1 フィルター」）
- 2 次: $\left\{\frac{1}{8}, \frac{3}{8}, \frac{3}{8}, \frac{1}{8}\right\}$
- 3 次: $\left\{\frac{1}{16}, \frac{1}{4}, \frac{3}{8}, \frac{1}{4}, \frac{1}{16}\right\}$

まとめ

移動平均は計算が簡単ですが、データの両端付近は計算できず「欠測」になってしまうという弱点があります。二項フィルターは、注目している時点に近いデータほど重視（重み付け）して滑らかにする手法です。

例え話による解説

写真加工アプリの「ぼかし（ブラー）」機能のようなものです。画像のザラザラした細かいノイズ（高周波）を、周囲のピクセルの色を平均化することで滑らか（低周波成分を抽出）にします。

7.2.2　たたみ込み型フィルターと理想フィルターの課題

関数 g と h の**たたみ込み積分**は $(g*h)(t) \equiv \int_{-\infty}^{\infty} g(x)h(t-x)dx$ と定義されます。これをフーリエ変換すると、以下のようになります。

$$\begin{aligned}\mathcal{F}(g*h) &= \iint_{-\infty}^{\infty} g(x)h(t-x)dx\, e^{-2\pi i f t}dt \\ &= \int g(x) \int h(t-x)e^{-2\pi i f(t-x)}dt\, e^{-2\pi i f x}dx \\ &= \int g(x)\mathcal{F}(h)e^{-2\pi i f x}dx = \mathcal{F}(g)\cdot\mathcal{F}(h)\end{aligned}$$

ここで $\mathcal{F}(g)$ を応答関数 $B(f)$ とみなせば、これは重み関数 $g(x)$ を用いたフィルタリングそのものです。つまり、**移動平均や二項フィルターはたたみ込み型フィルターの一種**と言えます。

通過させたい成分を 100% 通し、それ以外を完全に遮断するフィルターを**矩形（理想）フィルター**と呼びますが、これは無限長データでしか実現できません。有限のデータで無理に理想フィルターを作ろうとすると、ギブス現象（波形のオーバーシュート）や**位相の反転 (Phase reversal)** が起きてしまいます。優れたフィルターには以下の 4 条件が求められます。

1. 阻止域での確実な減衰（確実にノイズを消す）
2. 平坦な通過域（残したい波の振幅を変えない）
3. 適切な遷移帯の幅（ギブス現象を防ぐ）
4. 位相変化がないこと（波のタイミングをずらさない）

まとめ

時間領域で「重みをつけて平均する（たたみ込み）」という計算は、周波数領域では「応答関数を掛け算する」ことと数学的に同じです。しかし、有限のデータに対してスパッと切れる理想的なフィルターを当てはめると、波形が歪んでしまう問題が生じます。

例え話による解説

厚紙をハサミで切る作業に似ています。「ここから先は 1 ミリも残さない」と直角に無理やり切ろう（理想フィルター）とすると、紙がグシャッと折れ曲がってしまいます（ギブス現象）。綺麗に仕上げるには、少し余裕を持ってなだらかなカーブで切る（適切な遷移帯の幅を持たせる）必要があります。

7.2.3 Lanczos フィルターと特性比較

単純な移動平均は「平坦な通過帯がない」「高周波の遮断が甘い」、そして何より「応答関数が負になる領域が存在し、**位相の反転**が生じる」という大きな欠点があります。二項フィルターは遮断特性は改善しますが、やはり平坦な通過帯を持たず遷移帯が広すぎます。

有限長のデータに対し、応答関数の遷移帯になだらかな傾斜を持たせることで数学的に導出されたのが**Lanczos (ランツォシュ) フィルター**です。重み係数は次のように定義されます。

$$w_j = \frac{\sin 2\pi f_c j}{\pi j} \frac{\sin(\pi j/J)}{\pi j/J} \quad (j = 0, \ldots, \pm J)$$

窓幅のパラメータ J を大きくするほど理想的な特性に近づきますが、**両端の欠測値が増加する**というトレードオフが生じます。

実際の適用例（Nino3 海面水温アノマリー）では、未処理のデータに対し、単純な 5 年移動平均、7 次二項フィルター、そして 10 年ローパス Lanczos フィルター（$J = 10$）を適用し、目的に応じてどのような波形が抽出されるかを比較・評価します。

まとめ

気候変動の研究などでは、波のタイミング（位相）がひっくり返ってしまうと「いつ現象が起きたか」を誤解してしまうため、移動平均ではなく Lanczos フィルターのような数学的に優れたフィルターが好んで使われます。ただし、両端のデータが多く削られてしまう点には注意が必要です。

例え話による解説

Lanczos フィルターは「高級なコーヒーフィルター」です。単純な移動平均（安い茶こし）だと粉が漏れたり（高周波の遮断が甘い）、コーヒー自体の味が変わったり（位相の反転）してしまいますが、高級フィルターなら味を変えずに純粋なコーヒーだけを抽出できます。ただし、フィルターが分厚い分、吸い込まれて飲めなくなるコーヒー（欠測データ）も増えてしまいます。

8　主成分分析

8.1　モード展開の基礎

8.1.1　時空間データの変数分離

空間 2 次元と時間 1 次元からなる時空間データにおいて、格子点数が膨大になると全体像を直感的に把握することが困難になります。しかし、変動の大部分はごく少数の「モード」の時間発展によって表現できることが多くあります。これを変数分離（少数 M のモードで展開）として定式化すると以下のようになります。

$$\xi(x,y,t) \to \sum_{m=1}^{M} \eta_m(x,y)\tau_m(t)$$

例えば、中学校の 1 クラス（生徒 40 人）の 5 教科の成績データ（5×40）に対し主成分分析を適用すると、以下のようなモードを抽出できます。

- **Mode 1**: 国語と社会を強く反映（文系的能力）
- **Mode 2**: 数学と理科を強く反映（理系的能力）
- **Mode 3**: 英語を強く反映

各生徒はこれら 3 つのモードに対応するスコアを持つことになり、わずか 3 つのモードで成績の多様性の大部分を捉えることができます。

まとめ

膨大な多次元データを、特徴的な少数の「モード（空間パターン）」と「その強さ（時間・個体ごとのスコア）」の掛け合わせの和として表現し直す手法がモード展開です。

例え話による解説

オーケストラの演奏に例えてみましょう。舞台上には 100 人の演奏者（膨大なデータ点）がいますが、実は「弦楽器のメロディ」「管楽器の伴奏」「打楽器のリズム」という 3 つの大きな役割（モード）だけで音楽の大部分が構成されています。個々の楽器の音をすべて追うのではなく、この 3 つのグループの音の強弱（スコア）を見るだけで、曲の全体像がすっきりと理解できるようになります。

8.2　2 地点のケースにおける定式化

8.2.1　未定乗数法と固有値問題への帰着

遠く離れた 2 地点の変数（例：ダーウィンとタヒチの気圧偏差）は、しばしば負の相関などを示します。2 次元の散布図において、全分散の大部分を表現できる直線の軸を数学的に決定します。新しい軸への射影成分を $\phi \equiv wx + vy$ とし、$w^2 + v^2 = 1$ の制約のもとで ϕ の分散 $\sigma^2_{\phi\phi}$ を最大化します。

$$\sigma^2_{\phi\phi} = w^2\sigma^2_{xx} + 2wv\sigma_{xy} + v^2\sigma^2_{yy}$$

ラグランジュの未定乗数法を用いると、この問題は共分散行列の固有値問題に帰着されます。

$$\begin{pmatrix} \sigma_{xx}^2 & \sigma_{xy} \\ \sigma_{xy} & \sigma_{yy}^2 \end{pmatrix} \begin{pmatrix} w \\ v \end{pmatrix} = \lambda \begin{pmatrix} w \\ v \end{pmatrix}$$

共分散行列は実対称行列であるため、固有値 λ_i は非負であり、固有ベクトルは互いに直交します。このとき、固有値 λ はその軸に沿った分散そのものを表します。

まとめ

データの散らばりが最大になる新しい軸を探す数学的操作は、共分散行列の固有値問題として解くことができます。得られた固有ベクトルが「新しい軸の向き」であり、固有値が「その軸方向へのデータのばらつき（分散）の大きさ」を表します。

例え話による解説

夜空に散らばる星の集まり（データ）の中で、一番長く星が連なっている方向（星座の軸）を見つける作業に似ています。ラグランジュの未定乗数法という望遠鏡を使うと、「ここが一番長く伸びている軸（第 1 主成分）」「それと直角に交わる 2 番目に長い軸（第 2 主成分）」というように、星の散らばりを綺麗に説明できる十字の基準線を引くことができます。

8.3 主成分分析 (PCA) の一般化

8.3.1 行列形式での定式化と変数の性質

空間 p 点、時間 s ステップの時系列データ行列 $\mathbf{Z}$（あらかじめ時間平均を差し引いたもの）に対して、共分散行列 $\mathbf{V}$ を考えます。

$$\mathbf{V} = \frac{1}{s}\mathbf{Z}^T\mathbf{Z}$$

固有値問題 $\mathbf{V}\boldsymbol{\xi}_i = \lambda_i \boldsymbol{\xi}_i$ を解くことで、正規直交系をなす固有ベクトル群 $\boldsymbol{\xi}_i$ が得られます。これを用いると、データ行列は変数分離形式で完全に再構成できます。

$$\mathbf{Z} = \sum_{i=1}^{m} \boldsymbol{\tau}_i \boldsymbol{\xi}_i^T \quad (\boldsymbol{\tau}_i \equiv \mathbf{Z}\boldsymbol{\xi}_i)$$

主成分時系列 $\boldsymbol{\tau}_i$ は互いに直交し、その分散は対応する固有値 λ_i に等しくなります。また、全固有値の総和は全空間分散の和に一致します。

まとめ

2 地点から多地点へ一般化しても、基本構造は同じです。データは「互いに直交する空間パターン（固有ベクトル）」と「直交する時間変化（主成分時系列）」の掛け合わせの足し算に分解でき、各モードの重要度（分散）は固有値によって決まります。

例え話による解説

複雑な味のスープ（データ行列 $\mathbf{Z}$）を分析するようなものです。分析器（PCA）にかけると、「塩味エキス」「旨味エキス」「辛味エキス」といった純粋な基本調味料（固有ベクトル $\boldsymbol{\xi}$）と、それぞれの「投入量」（主成分時系列 $\boldsymbol{\tau}$）に分解してくれます。全てのエキスと投入量を掛け合わせて足せば、元の複雑なスープの味が完全に再現できます。

8.3.2 用語、実例、および標準化

主成分分析には分野によって異なる用語が使われます。気象・海洋物理学では、空間パターン $\boldsymbol{\xi}_i$ を「経験直交関数 (EOF)」や「負荷量」と呼び、展開係数 $\boldsymbol{\tau}_i$ を「主成分 (PC)」と呼びます。$\lambda_i / \sum \lambda_j$ は寄与率を表します。

例えば、年平均海面水温 (SST) の解析では、わずか 3 つのモードで全分散の 55% 以上を説明できます（EOF1: 全球的な温暖化傾向, EOF2: ENSO 様パターンなど）。解釈を容易にするため、通常は空間パターン側に単位を持たせ（有次元化）、時間変動側を無次元（標準化）にして可視化します。

$$\hat{\boldsymbol{\tau}}_i = \frac{\boldsymbol{\tau}_i}{\sqrt{\lambda_i}} \quad \text{(標準化 PC)}, \quad \hat{\boldsymbol{\xi}}_i = \sqrt{\lambda_i}\boldsymbol{\xi}_i \quad \text{(有次元化 EOF)}$$

まとめ

気象分野では PCA を EOF 解析と呼ぶことが多く、上位の少数のモードだけで気候変動の大きな特徴を捉えられます。グラフ等で示す際は、空間マップ（EOF）に実際の物理量（温度など）を持たせ、時系列グラフ（PC）は相対的な強弱の推移として描くのが一般的です。

例え話による解説

地球全体の気温変化を数台のエアコンに例えます。第 1 モードは「地球全体をじわじわ暖める巨大ヒーター（温暖化）」、第 2 モードは「太平洋の熱を数年周期で揺さぶる巨大扇風機（エルニーニョ）」です。有次元化とは、空間マップの方に「このヒーターは最大で何 ℃ 温度を上げるか」という具体的なスペック（単位）を書き込み、時系列グラフの方には「今、ダイヤルが何メモリ目か」という強さの比率だけを記録するような整理術です。

8.4 解析における工夫：重み付けと双対形式

8.4.1 空間重み付けの必要性

観測点や格子点が不均一に分布している場合（例：極に向かうほど緯線円が縮む等間隔の緯度経度格子）、密集域の分散が過大評価され、PCA がその領域の変動を優先して抽出してしまいます。これを防ぐため、各データ点が代表する面積の平方根 $\sqrt{\Delta A}$ をデータに掛けて重み付けを行います。緯度経度格子の場合は $\sqrt{\cos\theta}$（θ は緯度）などの重み係数を使用します。

まとめ

格子点の密度に偏りがあるデータでは、そのまま PCA を行うと「点の多い狭い地域」の影響が強くなりすぎます。面積に応じた重み付けを行うことで、地球全体を公平な基準で評価できるようになります。

例え話による解説

全国アンケートを実施したとき、東京の回答者が 10,000 人で、鳥取の回答者が 100 人だったとします。そのまま集計（分散を計算）すると「東京の局地的な流行」が「日本全体の特徴」として抽出されてしまいます。これを防ぐために、各地域の人口比率に応じた「重み（係数）」を掛けて、日本全体の声を公平なバランスに修正するプロセスと同じです。

8.4.2　双対形式 (Dual formalism)

気候データのように、空間格子点数 p が時間ステップ数 s よりもはるかに多い（$p \gg s$）場合、$p \times p$ の共分散行列は巨大になり計算コストが膨大になります。このとき、時間共分散行列 $\mathbf{L} \equiv \frac{1}{s}\mathbf{Z}\mathbf{Z}^T$ $(s \times s)$ を用いて固有値問題を解き、後から空間パターンを求める「双対形式」を用いることで、計算速度を劇的に向上させることができます。

まとめ

「空間点の数」よりも「時間の数」が少ない場合、相関を計算する行列の次元を時間側にすり替える（双対形式）ことで、計算の負担を大幅に減らすテクニックです。

例え話による解説

10 万人の生徒（空間点）が、1 年間に 12 回のテスト（時間ステップ）を受けたとします。10 万人同士の相関（10 万 ×10 万の表）を計算するのは途方もない作業ですが、逆に「第 1 回のテストと第 2 回のテストの相関（12×12 の表）」を計算するのは一瞬です。双対形式は、このように視点を反転させることで、同じ答えを圧倒的なスピードで導き出す数学のショートカットです。

8.5　結果の解釈と主成分分析の拡張

8.5.1　North の経験則と物理的意味の検証

PCA で得られたモードが本当に物理的に意味のある（卓越した）パターンか、単なるノイズの混ざった人為産物かを評価するため、North et al. (1982) の経験則が用いられます。固有値のエラーバー $\Delta\lambda_i = \lambda_i\sqrt{2/s_e}$ を計算し、隣接するモード間でエラーバーが重複しなければ、統計的に有意に分離しているとみなします。また、北極振動 (AO) のように、抽出されたモードが直交していない独立した物理モードの見かけ上の重ね合わせである可能性にも注意が必要です。

まとめ

計算機が出力した主成分が、自然界で本当に起きている物理現象を表しているとは限りません。固有値の誤差範囲（エラーバー）を調べてモードが混ざっていないか確認することや、空間パターンの極同士の実際の相関を確認することが重要です。

例え話による解説

ラジオのチューニングに似ています。周波数の離れた強い放送局（固有値の差が大きいモード）は綺麗に聴き取れますが、強さが同じくらいの放送局が近くにある（固有値が近接している）と、音が混ざってしまいどちらの曲か分からなくなります。North の経験則は「この放送（モード）は混信せずに単独で聴き取れているか」をチェックするノイズチェッカーの役割を果たします。

8.5.2　主成分分析のバリエーション

目的に応じて PCA にはいくつかの派生手法があります。

- **相関行列に基づく PCA**: 空間的な変動の大きさの差をなくし、広域パターンを抽出する。
- **結合 PCA**: 複数の異なる変数（気温、気圧など）を連結して同時に解析する。
- **拡張 EOF (EEOF / MSSA)**: 空間次元に時間ラグ次元を含め、移動・伝播する現象を抽出する。
- **季節 EOF**: 季節変化を空間次元に含めて年ごとの変動を捉える。

まとめ

基本的な PCA の枠組みを応用することで、単位の違うデータを混ぜて解析したり、時間的な「ズレ（波の伝播）」を考慮した解析ができるようになります。

例え話による解説

普通の PCA が「1 枚の写真」から特徴を探すものだとすれば、拡張 EOF は「パラパラ漫画」として少しずつ時間をずらした画像をセットにして解析することで、「右から左へ動いている」という動きそのものを一つの特徴として抜き出すことができる高性能なスキャナーです。

8.5.3　主成分の回転 (Rotation)

通常の PCA では、第 2 モード以降に対して「前のモードと直交しなければならない」という強い数学的制約が課されるため、高次モードが物理的意味を失いやすくなります。これに対処するため、抽出された固有ベクトルの線形結合を作り、直交制約を緩めたり再配分する「回転（Rotation）」を行います。代表的なバリマックス回転では、負荷量が 0 か大きな値に二極化するように調整し、局所的なテレコネクションパターン（NAO や PNA など）を明瞭に分離します。

まとめ

数学的な「直交（全く重ならない）」という厳しいルールによって抽出された不自然なパターンを、後から線形代数的に「回転」させることで、より現実の物理現象（局所的な変動）に近い自然なパターンへと変換する技術です。

例え話による解説

大きな体育館を照らす照明を考えてください。通常の PCA は「全体を照らす巨大なメインライト」と「それに直交する（メインの影を消すような）複雑な形状のサブライト」の組み合わせで表現しようとします。しかし「回転」を行うと、この不自然な照明設定を解体し、「ステージ用のスポットライト」「観客席用のスポットライト」といったように、各エリアを独立して照らす現実的で扱いやすい照明の組み合わせに再編成してくれます。

9　最大共分散分析

9.1　最大共分散分析 (MCA) の基本概念

9.1.1　MCA の導入と目的

PCA（主成分分析）や EOF 解析が「単一の変数」の全分散を最も説明するモードを探す手法であるのに対し、最大共分散分析（Maximum Covariance Analysis, MCA）は「2 つの異なる変数」の共分散を最大化するモードを探す手法です。特異値分解解析（SVD 解析）と呼ばれることもあります。

時間ステップ数 s が共通であれば、空間格子点数 p_x, p_y が異なっていても、また空間解析領域が全く異なっていても解析が可能です。この解析では、2 変数 $\mathbf{X}$ と $\mathbf{Y}$ からなる $p_x \times p_y$ の共分散行列 $\mathbf{C}$ を用います。

$$\mathbf{C} = \frac{1}{s}\mathbf{X}^T\mathbf{Y}$$

実例として、北半球の高度場と熱帯の海面水温の MCA では、第 1 モードで ENSO に関連する応答（二乗共分散寄与率 68%）などが抽出され、各モードに対して $\mathbf{X}$ 側と $\mathbf{Y}$ 側の 2 本の時系列が得られます。

まとめ

MCA は、種類の違う 2 つのデータセット（例：気温と気圧）の間で、関係性が最も強い空間パターンと時間変化のペアを抽出する手法です。データサイズや対象領域が異なっていても時間を揃えれば適用可能です。

例え話による解説

男女のペアダンス競技に例えてみましょう。PCA は「一人のダンサーがどれだけ大きく美しく動くか」を分析しますが、MCA は「二人のダンサーの動きがどれだけ見事にシンクロしているか（共変動）」に注目して分析する手法です。

9.1.2　特異値分解 (SVD) と解析手順

MCA の計算は特異値分解 (Singular Value Decomposition, SVD) によって行われます。任意の実行列 $\mathbf{C}$ は以下のように分解できます。

$$\mathbf{C} = \mathbf{U}\,\mathbf{V}^T$$

ここで、$\mathbf{U}$ は左特異ベクトルからなる正規直交行列、$\mathbf{V}$ は右特異ベクトルからなる正規直交行列、 は対角成分に特異値 $\sigma_i \geq 0$ を並べた行列です。

実際の解析手順は以下の通りです。

1. あらかじめ時間平均を差し引いた 2 つのデータ行列 $\mathbf{X}$, $\mathbf{Y}$ から、共分散行列 $\mathbf{C} = \frac{1}{s}\mathbf{X}^T\mathbf{Y}$ を計算する。
2. $\mathbf{C}$ を特異値分解し、空間次元の特異ベクトル $\mathbf{u}_i, \mathbf{v}_i$ と特異値 σ_i を得る。
3. 空間特異ベクトルへ元データを射影し、各変数の展開時系列 $\boldsymbol{\tau}_{xi} = \mathbf{X}\mathbf{u}_i$ と $\boldsymbol{\tau}_{yi} = \mathbf{Y}\mathbf{v}_i$ を算出する。

まとめ

2 つのデータの共分散行列に対して SVD（特異値分解）という数学的処理を実行し、得られたベクトルに元のデータを掛けることで、お互いの連動性を表す 2 つの時系列データを取り出します。

例え話による解説

SVD は、複雑に絡み合った 2 つの異なる言語間の「翻訳辞書」を作る作業に似ています。左特異ベクトルと右特異ベクトルはそれぞれの言語における「対応する単語・概念」であり、特異値はその概念が「どれくらい重要か（頻出するか）」を表しています。

9.2　モードの性質と寄与率

9.2.1　時系列の直交性と二乗共分散寄与率

得られた時系列の間には、同じモード番号 $(i = j)$ であれば共分散が特異値 σ_i に等しくなり、異なるモード番号間 $(i \neq j)$ では共分散が 0 になるという直交性があります。

$$\frac{1}{s}\boldsymbol{\tau}_{xi} \cdot \boldsymbol{\tau}_{yj} = \sigma_i \delta_{ij}$$

しかし、PCA とは異なり、$\mathbf{X}$ 側の時系列同士 $(\boldsymbol{\tau}_{xi}$ と $\boldsymbol{\tau}_{xj})$ や $\mathbf{Y}$ 側の時系列同士は、一般には直交しません。また、各モードが全体の中でどれだけの割合を説明しているかは、二乗共分散寄与率 (Squared Covariance Fraction, SCF) で評価します。これはフロベニウスノルム（特異値の二乗和に等しい）を用いて次のように定義されます。

$$\mathrm{SCF}_m \equiv \frac{\sigma_m^2}{\|\mathbf{C}\|_F^2} = \frac{\sigma_m^2}{\sum_{i=1}^{M} \sigma_i^2}$$

まとめ

MCA で得られる時系列は、ペア間では別のモードと完全に無関係（無相関）になりますが、同じデータ内の別のモードとは必ずしも無相関になりません。各モードの重要性は、全体の共分散の何割を占めるかを示す二乗共分散寄与率（SCF）で測ります。

例え話による解説

2 つの企業の業績連動性を分析するようなものです。第 1 の要因（景気）による両社の連動と、第 2 の要因（季節）による連動は明確に分離できますが、片方の企業の中だけで見ると「景気による変化」と「季節による変化」が完全に独立しているとは限らない、ということです。

9.2.2　結合 PCA/EOF との比較

2 つの変数を結合してデータ行列 $\mathbf{Z} \equiv (\mathbf{X} \mid \mathbf{Y})$ を作り、その共分散行列 $\tilde{\mathbf{V}}$ に対して PCA を行う手法を「結合 PCA/EOF」と呼びます。この場合、共分散行列の対角ブロックには $\mathbf{X}$ や $\mathbf{Y}$ 単独の共分散が含まれるため、行列全体の固有値問題を解くと、各変数単独の分散に強く引きずられ、純粋な共変動のみを抽出できる保証がありません。一方、MCA は非対角ブロックである $\mathbf{X}$ と $\mathbf{Y}$ の相互共分散行列のみを特異値分解するため、純粋に 2 変数の共変動（covariation）のみに基づいてモードを抽出できるという本質的な違いがあります。

まとめ

変数を単純につなげて PCA を行うと各変数の自己分散の影響を受けてしまいますが、MCA は変数間の「相互関係（共分散）」のみを純粋に取り出すことができるため、異なるデータ間の連動性を見たい場合に優れています。

例え話による解説

結合 PCA が「2 人の個人の営業成績の合計」を最大化しようとする評価だとすれば、MCA は「2 人の協力プレイによって生まれた成果」だけを純粋に抽出する評価システムです。単独で稼ぐ力がいくら高くても、MCA では連係プレーができていなければ評価されません。

9.3　空間パターンの解釈と応用

9.3.1　回帰図・相関図と空間直交性

得られた時系列を用いて、空間的なパターンを地図上に表現する際、2 種類のアプローチがあります。

- **同質回帰図**: 変数を「自身の時系列」に回帰させたもの。
- **異質回帰図**: 変数を「相手の時系列」に回帰させたもの。

数式上、異質回帰パターンは対応する特異ベクトル $\mathbf{u}_m$ の有次元化表現そのものになるため、異なるモード間で互いに空間的に直交するという性質を持ちます。一方、同質回帰パターンは一般に直交しません。また、異質相関は同質相関よりも値が低く出ます。関連性を過大評価せず保守的に提示するためには、異質図 (Heterogeneous maps) を提示することが推奨されます。

まとめ

結果を地図上に図示する際、相手側の時間変化を基準に自分の空間パターンを描く「異質回帰図」を使うと、モード間の直交性が保たれ、データ間の関連性を過大評価しにくくなります。

例え話による解説

「自分自身の基準」ではなく「相手の基準」で自分を評価するようなものです。自分がどれだけ変化したか（同質）ではなく、相手の変化にどれだけ正確についていけたか（異質）を地図に描くことで、より厳密で信頼できるペアの連動性が視覚化されます。

9.3.2　MCA に関する補足事項と解析例

MCA においても PCA と同様に、格子点の面積の違いによる偏りを防ぐための空間重み付け（$\sqrt{\Delta A}$ など）が必須です。また、各格子点でデータを標準化してから SVD を適用する「相関に基づく MCA」も存在します。具体的な応用例として、梅雨前線帯における降水と熱移流の共変動解析などが挙げられます。この解析により、降水帯の南北変位と、それに伴う対流圏下層の水平風や温位移流の緊密な結合構造が明瞭に抽出されます。

まとめ

MCA を実行する前には、格子点の面積重み付けを忘れてはいけません。適切に処理を行うことで、降水量と風の動きなど、一見異なる物理メカニズムの背後にある緊密な連動性を明確に捉えることができます。

例え話による解説

全国アンケートで「都市部」ばかりの意見を重視しないよう、人口密度に応じて重み付けをするのと同じです。正しい重み付けをして降水と風をペアで分析すると、「雨が降るパターンの裏で、風がどうやって湿気を運んでいるか」という自然界の見事な連係プレーが浮き彫りになります。