地球物理データ解析レジュメ 2

2026 年 10 月 30 日

目次

1 イントロダクション 2

1.1 データとは 2

1.2 正問題と逆問題 4

1.3 線形問題と非線形問題 5

1.4 未解決問題 6

2 確率論の基礎 8

2.1 平均、分散、中央値 8

2.2 偏差と不偏推定量 9

2.3 確率分布 11

2.4 ベイズの定理 13

2.5 独立性 14

2.6 情報理論の基礎 15

2.7 確率分布の変数変換 17

1　イントロダクション

1.1　データとは

1.1.1　GNSS による高分解能な地殻変動観測

ここ数十年、私たちの生活のあらゆる場面でデータが爆発的に増加しており、データサイエンスが急速に台頭しています。固体地球科学の分野もその例外ではありません。例えば、日本では国土地理院（GSI）が運用する 1300 以上の GNSS 観測網（GEONET）が約 15〜20km 間隔で展開され、地球の変形を継続的に監視しています。さらに近年では、通信会社のソフトバンクなどの民間企業が、自動運転などの商業目的で 3300 以上の観測点を持つより高密度な GNSS 網を構築しました。これらを組み合わせることで平均 5〜10km という非常に高密度な観測網が実現し、かつてない高解像度で地殻の歪み速度を算出することが可能になっています。

まとめ

民間と公共の GNSS 観測網を統合することで、非常に高解像度かつ高密度な地殻変動データの取得が可能になった。

例え話による解説

GNSS 観測網は、地球の表面に貼られた無数の「モーションキャプチャのマーカー」のようなものです。マーカーの数が多ければ多いほど、地球の表面がどのように歪み、動いているのかという細かな動きを、精細な CG アニメーションのように滑らかに把握できるようになります。

1.1.2　SAR 衛星と InSAR 技術による面的な変形観測

合成開口レーダー（SAR）を搭載した衛星も、地球の変形を監視するために数日から数十日ごとに地表の画像を撮影しています。異なる時期に取得された 2 つの画像を比較し、その間の地表の変形を抽出する手法は SAR 干渉法（InSAR）と呼ばれます。この技術を用いると、空間解像度 10m で 50km 四方の InSAR 画像には約 2 億 5000 万個（2.5×10^8）ものデータポイントが含まれることになり、非常に情報量の多い高密度なデータセットが得られます。これにより、大地震などに伴う地表の広範な変形を面的に、かつ詳細に捉えることができます。

まとめ

SAR 干渉法（InSAR）を用いることで、衛星画像から地表の微小な変形を面的かつ高解像度に抽出でき、1 枚の画像から膨大なデータが得られる。

例え話による解説

InSAR は、地球の表面を上空から定期的にスキャンする「超高解像度の 3D スキャナー」のようなものです。過去と現在のスキャン結果を重ね合わせて「間違い探し」をすることで、地表が数ミリから数センチ単位でどう動いたかが、まるで等高線のようにくっきりと浮かび上がります。

1.1.3　高密度な地震計ネットワークと最新の DAS 技術

地震計による観測網はさらに高密度に展開されています。日本国内だけでも、防災科学技術研究所や気象庁、大学などが数千の地震計を設置しており、巨大地震に伴う詳細な地震波の伝播を可視化することができます。地震計は通常 0.01 秒ごとにデータをサンプリングするため、過去 20 年分のデータだけでも 1 ペタバイトを超える膨大な量になります。世界規模での地震観測網の構築も進む中、近年では地中や海底に敷設された光ファイバーケーブルを利用して数メートル間隔で歪みを計測する「分散型音響センシング（DAS）」技術が登場しました。これにより、取得される地震データの量はさらにインフレ状態となり、地震のメカニズムや地球内部の構造に関するさらなる知見をもたらしています。

まとめ

国内外に張り巡らされた地震計や最新の光ファイバー技術（DAS）により、膨大かつ高精度なデータが蓄積され続けている。

例え話による解説

世界中の地震観測網は、地球全体に当てられた「巨大な聴診器」の束です。さらに最新の DAS 技術は、身の回りに張り巡らされたインターネットの光ケーブルそのものを「何万個もの超小型マイク」として代用するような技術です。これにより、地球のわずかな鼓動をどこからでも高音質で録音できるようになりました。

1.1.4　本講義の目的：データサイエンスの基礎の習得

他分野と同様に、固体地球科学の分野でも、地震の検知・位置特定・分類や異常な地表変形の自動検知など、様々な目的で機械学習（Machine Learning）や深層学習（Deep Learning）の応用が急速に広がっています。しかし、本講義では最新の機械学習技術の表層的な使い方を学ぶわけではありません。その代わりに、現在の AI アルゴリズムの内部構造（ブラックボックス）を正しく理解し、将来的には自ら新しいアルゴリズムを開発できるようになるための、「データサイエンスの基礎」を徹底的に学ぶことを目的としています。

まとめ

本講義の狙いは、単に AI ツールを使うことではなく、その背景にある「データサイエンスの基礎理論」を学び、自らアルゴリズムを開発できる力を養うことである。

例え話による解説

最新の AI ツールを使うのは、便利な「全自動調理器」に頼って料理をするようなものです。本講義では、調理器のボタンの押し方を学ぶのではなく、食材の性質や火の通り方といった「料理の基本法則」を学びます。基礎を知ることで、誰かの作ったレシピに従うだけでなく、自分だけのオリジナルレシピ（新しいアルゴリズム）を自在に作れるシェフを目指します。

1.2　正問題と逆問題

1.2.1　地表の観測データと断層モデル

固体地球科学では、地下深くで何が起きているかに関心がありますが、地下を直接観測することは極めて困難であり、測定は主に地表で行われます。したがって、目に見えない地下の情報を、地表の測定値から抽出する必要があります。

簡単な例として、弾性・均質・等方な半無限媒質中にある、鉛直で無限に長い横ずれ断層による地表の変形を考えます。ここで、断層は地表から深さ D までが固着（ロック）しており、それより深い部分で右横ずれ速度 s ですべっていると仮定します。この場合、鉛直方向および断層直交方向の変位はゼロになります。鉛直断層が $x_1 = x_0$ の位置にあるとき、断層に平行な変位 u_2 は x_1 の関数として次のように表されます。

$$u_2(x_1) = \frac{s}{\pi} \tan^{-1}\left(\frac{x_1 - x_0}{D}\right) \tag{1.1}$$

まとめ

地下を直接見ることができないため、地表で観測された変形データと物理モデル（数式）を結びつけて、地下の断層の深さや滑り速度などを推定するアプローチが必要となる。

例え話による解説

これは「影絵」から元の物体の形を当てるようなものです。スクリーン（地表）に映った影（地表の変形データ）の形を見て、光源とスクリーンの間にある手や物（地下の断層）がどんな形をしていて、どれくらい動いているのかを推理していくプロセスに似ています。

1.2.2　観測方程式と正問題・逆問題の定義

より一般化すると、式 (1.1) は次のように書き換えることができます。

$$\mathbf{d} = G(\mathbf{m}) \tag{1.2}$$

これは**観測方程式**と呼ばれます。先ほどの断層の例では、$\mathbf{d} = [u_2^{(1)}, \ldots, u_2^{(i)}, \ldots, u_2^{(N)}]^T$、$\mathbf{m} = [s, x_0, D]^T$ となります（ここで $u_2^{(i)}$ は i 番目の観測点における変位、T は行列の転置を表します）。ここで、$\mathbf{d}$ は**データベクトル**、$\mathbf{m}$ は**モデルパラメータ**、G は**データカーネル**とそれぞれ呼ばれます。

式 (1.2) は、モデル $\mathbf{m}$ が与えられれば、データ $\mathbf{d}$ が容易に計算できることを示しています。このように、原因（モデルパラメータ）から結果（データ）を導き出すことを**正問題（Forward problem）**と呼びます。一方で、観測されたデータ $\mathbf{d}$ から未知のモデル $\mathbf{m}$ を推定することを**逆問題（Inverse problem）**と呼びます。正問題とは異なり、逆問題を解くことは一筋縄ではいかないことが多く、データサイエンスにおける重要なテーマとなります。

まとめ

原因（モデル）から結果（データ）を計算するのが「正問題」。観測データ（結果）から原因（モデル）を推定するのが「逆問題」である。地球科学における地下構造の推定は、主にこの逆問題を解くことによって行われる。

例え話による解説

「正問題」は、レシピと材料（モデルパラメータ）がわかっている状態で、どんな料理（データ）ができるかを予測することです。対して「逆問題」は、目の前に出てきた料理（データ）を食べて、どんな材料がどれくらい使われているか（モデルパラメータ）を推理することです。食べるだけで隠し味まで正確に当てるのは難しいため、逆問題を解くには様々な数学的工夫が必要になります。

1.3 線形問題と非線形問題

1.3.1 線形関数の定義とパラメータの性質

数学において、関数 G が線形であるためには、以下の 2 つの条件（加法性と斉次性）を満たす必要があります。

$$G(\mathbf{m}_1) + G(\mathbf{m}_2) = G(\mathbf{m}_1 + \mathbf{m}_2) \tag{1.3}$$

$$G(k\mathbf{m}) = kG(\mathbf{m}) \tag{1.4}$$

前節で示した断層変位の式 (1.1)（$\tan^{-1}$ を含む式）は、明らかに非線形関数です。しかし、もし断層の位置 x_0 と深さ D がアプリオリ（事前）に与えられており、滑り速度 s のみが未知のモデルパラメータであると仮定すれば、この方程式は線形になります。言い換えると、パラメータ x_0 や D は観測値に対して「非線形」な関係を持ちますが、パラメータ s は観測値に対して「線形」な関係を持っていることになります。

まとめ

未知のパラメータが数式のどこに組み込まれているかによって、問題が線形になるか非線形になるかが変わる。同じ方程式でも、何を未知数とするかで性質が変化する。

例え話による解説

線形とは「単純な比例と足し算が成り立つ素直な世界」です。例えば「お肉 100g で 200 円なら、300g で 600 円（3 倍）」というのが線形（滑り速度 s の関係）です。しかし、お肉の「熟成期間（D）」や「産地（x_0）」が変わると、味や価格の変化は単純な掛け算では予測できなくなります。これが非線形の関係です。

1.3.2 線形問題の行列表現と解の導出

もし推定したいすべてのモデルパラメータが観測値に対して線形の関係を持っていれば、データカーネル G を行列の形（$\mathbf{G}$）として表現することができます。その結果、観測方程式は次のように、シンプルに行列とベクトルの積として書き換えることが可能になります。

$$\mathbf{d} = \mathbf{Gm} \tag{1.5}$$

後述の章で詳しく議論されるように、線形問題は非線形問題に比べて数学的な取り扱いがはるかに容易であり、データサイエンスにおいて解を求めるためのアプローチが確立されています。

まとめ

すべてのパラメータが線形であれば、問題全体を行列計算 $\mathbf{d} = \mathbf{Gm}$ に帰着させることができ、数学的処理が飛躍的に簡単になる。

例え話による解説

全てが線形で表せる状態とは、複雑な問題を巨大な「エクセルの表（行列）」に整理できた状態に似ています。非線形の問題が「手探りで解くしかない複雑な知恵の輪」だとすれば、線形の問題は「公式や手順（行列計算）に当てはめれば確実に答えが出るパズル」のようなものであり、コンピューターに計算させるのが非常に得意な形と言えます。

1.4 未解決問題

観測データ $(x_1, y_1), \ldots, (x_N, y_N)$ を、線形関数 $y = ax + b$ でフィッティング（当てはめ）する問題を例に考えてみましょう。この場合、推定すべき未知のモデルパラメータは a（傾き）と b（切片）の 2 つです。データサイエンスや逆問題において、手元にある「観測データの数」と「推定したいモデルパラメータの数」のバランスによって、問題は大きく 3 つのケースに分類されます。

1.4.1 正定問題（Even-determined problem）

観測データの数とモデルパラメータの数が等しい（今回の例ではデータ数が 2 つである）場合を「正定問題」と呼びます。この状況では、すべてのデータを完全に説明（フィット）するモデルパラメータの組み合わせがただ 1 つ存在します。

まとめ

データ数と未知のパラメータ数が完全に一致している場合、連立方程式を解くのと同じように、すべての観測データを矛盾なく満たす「一意の解」を求めることができる。

例え話による解説

紙の上に点が「2 つ」だけあるとき、その両方を通る直線を定規で引くようなものです。2 つの点（データ）さえあれば、直線の傾きと切片（2 つのパラメータ）は迷うことなく 1 パターンに決まります。

1.4.2 過剰決定問題（Overdetermined problem）

観測データの数がモデルパラメータの数よりも多い場合を「過剰決定問題（優決定問題）」と呼びます。現実の観測データにはノイズや誤差が含まれるため、この場合、すべてのデータを完全に通るようなパラメータの組み合わせは存在しません。そのため、観測値とモデルによる予測値とのズレ（残差）を評価し、そのズレを

最小化するような「最適な」モデルパラメータを推定します。最も一般的に用いられるのは、残差平方和（誤差の 2 乗の合計）を最小にする「線形最小二乗法」です。

まとめ

データが多すぎるため完全な解は存在しない。代わりに、すべてのデータに対する誤差（残差）の合計が最も小さくなるような妥協点（最適解）を最小二乗法などで探すことになる。

例え話による解説

ばらばらな意見を持つ 100 人の人がいるとき、全員の要望を完全に満たす案を作ることは不可能なため、「全員の不満（誤差）の合計」が全体として一番小さくなるような妥協点を探す会議のようなものです。

1.4.3　劣決定問題（Underdetermined problem）

観測データの数がモデルパラメータの数よりも少ない場合を「劣決定問題」と呼びます。この場合、手元のデータだけでは情報が足りず、データを完全に説明できるモデルパラメータの組み合わせが無数に存在してしまいます。したがって、無数にある候補の中から唯一の解を決定するためには、観測データ以外の「事前情報（アプリオリな情報）」や、何らかの物理的・数学的な制約条件を新たに追加する必要があります。

まとめ

情報不足により解が無数に存在してしまう状態。解を一つに絞り込むには、事前知識や制約条件など、観測データ以外の追加情報（制約）が不可欠となる。

例え話による解説

「足して 10 になる 2 つの数字は？」と聞かれるようなものです。「5 と 5」「3 と 7」「-2 と 12」など答えが無限にあって特定できません。答えを 1 つに決めるには、「どちらも正の偶数で、片方はもう片方の 4 倍」といった別のヒント（事前情報・制約条件）がどうしても必要になります。

2　確率論の基礎

2.1　平均、分散、中央値

2.1.1　サンプル（標本）と平均値

データサイエンスにおいて、観測された個々のデータ（例えば 50 人の学生のテストの点数 $x^{(i)}$）を**サンプル（標本）**と呼びます。これらのサンプル全体の基本的な傾向を把握するための代表値の一つが**平均（Mean）**です。サンプル数が N のとき、平均 μ はすべてのサンプルの値を足し合わせ、サンプル数で割ることで求められます。

$$\mu = \frac{1}{N}\sum_{i=1}^{N} x^{(i)} \tag{2.1}$$

提示された 50 人のテストの点数の例では、計算された平均値は $\mu = 57.70$ となります。

まとめ

平均値は、集めたデータ全体の中心的な位置を示す最も基本的な統計量である。データの総和を個数で割って算出される。

例え話による解説

平均値は、食事会の「割り勘」のようなものです。たくさん食べる人（高得点）も少食の人（低得点）も一旦すべてのお金をテーブルに集め、全員で平等に等分したらいくらになるか、を計算しています。

2.1.2　分散と標準偏差

データが平均値の周りにどの程度散らばっているか（ばらつき）を示す指標が**分散（Variance）** σ^2 です。各サンプルが平均 μ からどれだけ離れているか（偏差）を 2 乗して足し合わせ、それを $N-1$ で割ることで求められます（不偏分散）。

$$\sigma^2 = \frac{1}{N-1}\sum_{i=1}^{N}\left(x^{(i)} - \mu\right)^2 \tag{2.2}$$

さらに、分散の平方根 $\sqrt{\sigma^2}$ をとったものを**標準偏差（Standard deviation）**と呼びます。分散は計算の過程で元のデータを 2 乗しているため単位が変わってしまいますが、平方根をとって標準偏差にすることで、元のデータと同じ単位でばらつきを評価できます。先ほどのテストの例では、分散 $\sigma^2 = 257.03$ であり、標準偏差は 16.03 となります。

まとめ

分散と標準偏差は「データの散らばり具合」を表す。値が大きいほどデータが平均から遠く離れて広く分布していることを意味する。

例え話による解説

標準偏差は、クラスの点数の「散らかり具合メーター」です。平均点が同じ 50 点でも、全員が 50 点前後を取っているクラス（メーター小）と、0 点と 100 点ばかりのクラス（メーター大）では状況が全く異なります。標準偏差を見れば、みんなが平均にどれくらい寄り集まっているかがわかります。

2.1.3　中央値（メジアン）とその有用性

データを小さい順（または大きい順）に並べたとき、ちょうど真ん中に位置する値のことを**中央値（Median）**と呼びます。データ数が偶数の場合（今回の $N = 50$ など）は、中央にある 2 つの値（25 番目と 26 番目）の平均をとります。今回の例では中央値は 54 となります。

中央値の最大の利点は、極端に大きい値や小さい値（外れ値）の影響を受けにくいことです。例えば、所得分布のように一部の大富豪が平均を大きく引き上げてしまうようなデータでは、平均値よりも中央値の方が「一般的な感覚」に近い実態を表す指標として適しています。

まとめ

中央値はデータを順位付けした際の真ん中の値である。極端な外れ値が含まれるデータセット（所得など）において、全体の実態を正確に把握するのに非常に役立つ。

例え話による解説

中央値は、クラス全員を「背の順」に並ばせたときに、ちょうど真ん中に立つ人の身長です。もしクラスに身長 3 メートルの巨人が突然転校してきても、平均身長は跳ね上がってしまいますが、「真ん中の人の身長（中央値）」はほとんど変わりません。一部の極端な人に振り回されない、とても頑丈な指標です。

2.2　偏差と不偏推定量

2.2.1　標本分散と不偏分散の違い

直感的には、分散を計算する際にデータの総数 N で割る次のような式を思い浮かべるかもしれません。

$$s^2 = \frac{1}{N} \sum_{i=1}^{N} \left(x^{(i)} - \mu \right)^2 \tag{2.3}$$

しかし、前節で示した式 (2.2) では $N - 1$ で割っていました。この理由を正当化するために**不偏推定量（Unbiased estimator）**という概念が導入されます。データサイエンスの主な目的の一つは、手元にある N 個のサンプル（標本）から、背後にある真の全体（母集団）の平均 $\hat{\mu}$ と分散 $\hat{\sigma}^2$ を推定することです。

式 (2.3) の s^2 の期待値 $E(s^2)$ を計算すると、以下のようになります。

$$
\begin{aligned}
E(s^2) &= E\left[\frac{1}{N}\sum_{i=1}^{N}(x^{(i)}-\mu)^2\right] \\
&= E\left[\frac{1}{N}\sum_{i=1}^{N}((x^{(i)}-\hat{\mu})-(\mu-\hat{\mu}))^2\right] \\
&= E\left[\frac{1}{N}\sum_{i=1}^{N}(x^{(i)}-\hat{\mu})^2 - 2(\mu-\hat{\mu})\frac{1}{N}\sum_{i=1}^{N}(x^{(i)}-\hat{\mu}) + (\mu-\hat{\mu})^2\right] \\
&= E\left[\frac{1}{N}\sum_{i=1}^{N}(x^{(i)}-\hat{\mu})^2 - (\mu-\hat{\mu})^2\right] \\
&= V(x^{(i)}) - V(\mu) = \hat{\sigma}^2 - \frac{\hat{\sigma}^2}{N} = \frac{N-1}{N}\hat{\sigma}^2
\end{aligned} \tag{2.4}
$$

この結果から、式 (2.3) の s^2 は真の分散 $\hat{\sigma}^2$ よりも少し小さく見積もってしまう**偏った推定量（Biased estimator）**であることがわかります。一方、式 (2.2) のように $N-1$（**自由度**と呼びます）で割った σ^2 は、期待値がぴったり真の分散と一致する**不偏分散（Unbiased variance）**となります。なお、標本平均 μ の期待値は次のように計算され、真の平均 $\hat{\mu}$ と一致するため、不偏推定量であると言えます。

$$
E(\mu) = E\left[\frac{1}{N}\sum_{i=1}^{N}x^{(i)}\right] = \frac{1}{N}\sum_{i=1}^{N}E(x^{(i)}) = \frac{1}{N}\cdot N\hat{\mu} = \hat{\mu} \tag{2.5}
$$

まとめ

標本のデータ数 N で割った分散は、母集団の真の分散を過小評価してしまう（偏りがある）。$N-1$ で割ることで、偏りのない正確な推定値（不偏分散）を得ることができる。

例え話による解説

クラスの一部の人（標本）の身長を測って、学校全体（母集団）の身長のばらつきを推測する状況を想像してください。一部のデータだけだと極端に背が高い・低い人が含まれにくく、ばらつきが「実際よりも小さく」見えてしまいます。この「見えにくくなった分」を補正するために、少し小さな数（$N-1$）で割ることで、ばらつきを本来の大きさに引き戻してあげるのが不偏分散です。

2.2.2　確率分布と期待値・分散の数学的定義

確率論の基礎として、確率分布、期待値、および分散の厳密な定義を確認します。離散確率分布 $P(x_i)$ と連続確率分布 $P(x)$ は、それぞれすべての確率を足し合わせる（または積分する）と 1 になる性質を満たします。

$$
\sum_{i} P(x_i) = 1 \tag{2.6}
$$

$$
\int_{-\infty}^{\infty} P(x)dx = 1 \tag{2.7}
$$

期待値 $E(x)$ は、それぞれの値にその確率を掛けて合計したものであり、次のように定義されます。離散型：

$$
E(x) = \sum_{i} x_i P(x_i) \tag{2.8}
$$

連続型：

$$E(x) = \int_{-\infty}^{\infty} xP(x)dx \tag{2.9}$$

また、**分散** $V(x)$ は、データが平均（期待値 μ）からどれだけ離れているかの期待値として定義され、計算を工夫することで「二乗の期待値」から「期待値の二乗」を引いた形に変形できるという非常に重要な性質を持ちます。

$$\begin{aligned} V(x) &= \int_{-\infty}^{\infty} (x-\mu)^2 P(x)dx = \int_{-\infty}^{\infty} (x^2 - 2x\mu + \mu^2)P(x)dx \\ &= \int_{-\infty}^{\infty} x^2 P(x)dx - 2\mu \int_{-\infty}^{\infty} xP(x)dx + \mu^2 \int_{-\infty}^{\infty} P(x)dx \qquad (2.10) \\ &= E(x^2) - 2\mu E(x) + \mu^2 = E(x^2) - (E(x))^2 \qquad (2.11) \end{aligned}$$

ここで μ は以下の通りです。

$$\mu = E(x) \tag{2.12}$$

まとめ

確率分布の総和（積分）は必ず 1 になる。また、分散 $V(x)$ は定義通りに計算するだけでなく、「二乗の期待値 $E(x^2)$」から「期待値の二乗 $(E(x))^2$」を引くことでも容易に計算できる。

例え話による解説

期待値は「宝くじを何度も買ったとき、1 回あたり平均して何円戻ってくるか」という見込みの金額です。分散は「その結果が毎回どれくらい派手にブレるか」というギャンブル性の強さを表します。「2 乗の期待値から期待値の 2 乗を引く」という公式は、このブレの計算をより少ない手間で導き出せる、データサイエンスにおける非常に便利なショートカット（裏技）です。

2.3 確率分布

2.3.1 共分散と分散共分散行列

複数の変数（例えば、数学の点数 x_1 と物理の点数 x_2）を同時に扱う場合、それらの間にどのような関係があるかを評価するために**共分散（Covariance）**が用いられます。共分散は以下のように定義されます。

$$\mathrm{Cov}(x_1, x_2) = E\left[(x_1 - E(x_1))(x_2 - E(x_2))\right] \tag{2.13}$$

共分散の値からは、2 つの変数の連動性がわかります。

- $\mathrm{Cov}(x_1, x_2) > 0$：一方が増加すると他方も増加する傾向がある（正の相関）。
- $\mathrm{Cov}(x_1, x_2) < 0$：一方が増加すると他方は減少する傾向がある（負の相関）。
- $\mathrm{Cov}(x_1, x_2) = 0$：2 つの変数に相関関係がない（無相関）。

さらに、それぞれの変数の分散と、変数間の共分散を行列の形にまとめたものを**分散共分散行列（Variance-covariance matrix）**と呼びます。

$$= E\left[\begin{pmatrix} x_1 - E(x_1) \\ x_2 - E(x_2) \end{pmatrix}\begin{pmatrix} x_1 - E(x_1) \\ x_2 - E(x_2) \end{pmatrix}^T\right] = \begin{pmatrix} V(x_1) & \mathrm{Cov}(x_1, x_2) \\ \mathrm{Cov}(x_1, x_2) & V(x_2) \end{pmatrix} \tag{2.14, 2.15}$$

まとめ

共分散は 2 つの変数がどれだけ連動して変化するかを示す指標である。これと各変数の分散を 1 つの行列に整理したものが分散共分散行列であり、多変量データ解析の基礎となる。

例え話による解説

共分散は「2 人の行動のシンクロ率」です。A さんが走ったときに B さんも走ればプラス、A さんが走ったときに B さんが歩けばマイナス、お互い全く無関係に動いていればゼロになります。分散共分散行列は、クラス全員のペアのシンクロ率と、それぞれの個人の活動量（分散）を一枚のエクセル表（マトリックス）にまとめた一覧表のようなものです。

2.3.2 同時確率分布の正規化（総和・積分の性質）

複数の変数が特定の値をとる確率をまとめたものを**同時確率分布（Joint probability distribution）**と呼びます。単一の確率分布と同様に、同時確率分布においても、起こり得るすべてのパターンの確率を足し合わせる（連続変数の場合は積分する）と、必ず 1（100%）になるという正規化の性質を満たします。

離散型の場合：

$$\sum_i \sum_j P(x_{1(i)}, x_{2(j)}) = 1 \tag{2.17}$$

連続型の場合：

$$\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} P(x_1, x_2)dx_1dx_2 = 1 \tag{2.18}$$

これらをベクトル $\mathbf{x}$ を用いて一般化すると、次のように表現されます。

$$\int_{-\infty}^{\infty} P(\mathbf{x})d\mathbf{x} = 1 \tag{2.19, 2.20}$$

まとめ

同時確率分布は複数の出来事が同時に起こる確率を表す。変数がいくつあっても、考え得るすべての組み合わせの確率を合計（積分）すると必ず 1 になる。

例え話による解説

同時確率分布は「ルーレットとサイコロを同時に振ったときの結果の一覧表」です。片方だけを見るのではなく、「ルーレットが赤で、かつサイコロが 3」というようなペアの結果を考えます。どんな組み合わせであっても、起こり得るすべてのパターンの確率を全部かき集めれば、必ずピッタリ「1（100% の確率）」になります。

2.3.3　周辺確率分布（周辺化）

複数の変数の同時確率分布が与えられているとき、そこから「特定の変数だけの確率分布」を取り出したい場合があります。このとき、関心のない変数のすべての可能性について確率を足し合わせる（積分して消去する）操作を**周辺化（Marginalization）**と呼び、得られた分布を**周辺確率分布**と呼びます。

例えば、2 変数 x_1, x_2 の同時確率分布 $P(x_1, x_2)$ から x_1 だけの分布を求める場合は、x_2 について積分を行います。

$$P(x_1) = \int_{-\infty}^{\infty} P(x_1, x_2) dx_2 \tag{2.21}$$

$$P(x_2) = \int_{-\infty}^{\infty} P(x_1, x_2) dx_1 \tag{2.22}$$

これを N 個の変数に拡張した場合、関心のある変数 x_i 以外のすべての変数で積分を行います。

$$P(x_i) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} P(\mathbf{x}) dx_1 dx_2 \ldots dx_{i-1} dx_{i+1} \ldots dx_N \tag{2.23}$$

まとめ

同時確率分布から、不要な変数をすべて積分（または総和）して消去することで、特定の変数だけの確率分布（周辺確率分布）を抽出する計算操作を周辺化と呼ぶ。

例え話による解説

周辺化は、アンケートの「年代別の男女クロス集計表」から「年代だけの合計」や「男女別の合計」を抜き出す操作に似ています。表の端（周辺）にある小計欄を見ているのと同じです。例えば、数学と物理の点数の分布図から、物理の点数を上から下へ全部押しつぶして（足し合わせて）、「数学だけの点数分布」のグラフを作るような作業を指します。

2.4　ベイズの定理

2.4.1　条件付き確率とベイズの定理の導出

2 つの変数（例えば x_1 と x_2）が与えられたとき、一方が起こったという条件の下でもう一方が起こる確率を**条件付き確率（Conditional probability）**と呼びます。同時確率分布 $P(x_1, x_2)$ は、周辺確率分布（ここでは**事前確率分布**とも呼ばれます）と条件付き確率を用いて次のように 2 通りで表すことができます。

$$P(x_1, x_2) = P(x_1)P(x_2|x_1) = P(x_2)P(x_1|x_2) \tag{2.24}$$

この式の右側の等式を $P(x_1|x_2)$ について解く（移項する）ことで、データサイエンスや統計学において極めて重要な**ベイズの定理（Bayes' theorem）**が導かれます。

$$P(x_1|x_2) = \frac{P(x_1)P(x_2|x_1)}{P(x_2)} \tag{2.25}$$

まとめ

ベイズの定理は、ある事象（x_2）が観測されたという新しい情報をもとに、元々の確率（事前確率 $P(x_1)$）を、より精度の高い確率（事後確率 $P(x_1|x_2)$）へと更新するための強力な計算規則である。

例え話による解説

ベイズの定理は「推理小説の探偵の思考プロセス」そのものです。最初は容疑者全員を同じくらい疑っています（事前確率）が、「現場に犯人のものらしき足跡があった」という新しい証拠（条件）が見つかるたびに、「この足跡サイズなら、あの人が犯人である確率はこれくらいに跳ね上がるな」と、頭の中の疑いの度合いをリアルタイムに更新（事後確率）していきます。

2.5 独立性

2.5.1 確率変数の独立性の定義

2 つの変数 x_1 と x_2 が互いに全く影響を及ぼし合わないとき、これらは**独立（Independent）**であると言います。数学的には、2 つの変数の同時確率分布が、それぞれの周辺確率分布の単なる掛け算で表せる場合に「独立である」と定義されます。

$$P(x_1, x_2) = P(x_1)P(x_2) \tag{2.29}$$

もしこの等式が成り立たない場合、それらの変数は**従属（Dependent）**関係にあります。

まとめ

2 つの変数が独立であるための必要十分条件は、同時確率がそれぞれの単独の確率（周辺確率）の積に完全に一致することである。

例え話による解説

独立性とは「全く別の世界で起きている出来事」です。例えば「東京で明日雨が降る確率」と「私が今サイコロで 6 を出す確率」は全く無関係です。そのため、両方が同時に起きる確率は、単にそれぞれの確率を掛け算するだけで計算できます。

2.5.2 無相関と独立の違い（無相関だが従属な例）

データ解析において非常に混同されやすい重要な性質があります。それは、独立な変数は常に無相関（共分散 $\mathrm{Cov} = 0$）になりますが、**「その逆は必ずしも真ではない（無相関だからといって独立とは限らない）」**ということです。つまり、相関（線形な関係）がなくても、非線形な依存関係（従属）が存在する場合があります。

その典型的な例として、次のような確率分布を考えます。

$$P(x_1, x_2) = \begin{cases} 1/2 & \text{if } |x_1 + x_2| \leq 1 \\ 0 & \text{otherwise} \end{cases} \tag{2.30}$$

この場合、それぞれの周辺分布は次のようになります。

$$P(x_i) = 1 - |x_i| \quad (i = 1, 2) \tag{2.31}$$

ここで $P(x_1, x_2) \neq P(x_1)P(x_2)$ となるため、定義上 x_1 と x_2 は**従属**です。さらに、条件付き確率を計算すると、

$$P(x_2|x_1 = c) = P(x_1|x_2 = c) = \frac{2}{c} \tag{2.32}$$

となり、確率が与えられた値 c に依存して変化することからも、両者がはっきりと従属関係にある（互いに影響し合っている）ことが証明されます。

まとめ

「独立ならば無相関」は成り立つが、「無相関ならば独立」は成り立たない。相関係数や共分散がゼロであっても、変数間に隠れた法則や制約（非線形な依存関係）が存在する場合がある。

例え話による解説

無相関だけど従属というのは、「トランポリンで遊ぶ 2 人」のような関係です。シーソー（相関あり）なら一方が上がれば必ずもう一方が下がりますが、トランポリンでは相手が跳んだからといって自分が決まった方向に動くわけではありません（無相関・直線的な関係はない）。しかし、同じトランポリンの膜に乗っている以上、相手の着地の反動で自分の跳べる高さやタイミングが確実に制限されます（従属・見えない制約がある）。

2.6 情報理論の基礎

2.6.1 離散確率分布のエントロピー

情報理論において、ある事象が確率 P で発生するとき、その事象が持っている「情報量」は次のように定義されます。

$$I \equiv -\log_2 P \tag{2.33}$$

（単位はビット：bits）。さらに、すべての事象が持つ情報量の期待値（平均）をとったものを**平均情報量**または**エントロピー** H と呼びます。

$$H = -\sum_i P_i \log_2 P_i \tag{2.34}$$

エントロピーは常に $H \geq 0$ を満たします。N 個の事象がある場合、結果が完全に予測できる（どれか 1 つの確率が 1 で他が 0）ときにエントロピーは最小値 $H_{\min} = 0$ となり、すべての事象が等確率（$P_1 = \cdots = P_N = 1/N$）で起こるときに最大値 $H_{\max} = \log_2 N$ となります。

まとめ

エントロピーは「不確実性」や「予測の難しさ」の度合いを表す指標である。結果がどれになるか全く予想がつかない（等確率の）とき、不確実性は最大（エントロピー最大）となる。

例え話による解説

エントロピーは「クイズの正解を知ったときの驚き度」です。最初から答えが 1 つしかない（確率 1）とわかっている問題は、答えを聞いても「やっぱりね」と思うだけで驚き（情報量）はゼロです。しかし、選択肢が 100 個あってどれが正解か全く見当がつかない問題（等確率）では、正解を聞いたときの「なるほど !」という驚き（情報量）が最大になります。

2.6.2 連続確率分布（正規分布）のエントロピー

連続確率分布の場合も同様にエントロピーを定義できます。代表的な例として、平均 μ、分散 σ^2 の正規分布 $\mathcal{N}(x;\mu,\sigma^2)$ を考えます。

$$\mathcal{N}(x;\mu,\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \tag{2.38}$$

この正規分布のエントロピー H は、以下のガウス積分を用いて計算すると、次のようなシンプルな形になります。

$$\int_{-\infty}^{\infty} e^{-x^2} dx = \sqrt{\pi} \tag{2.42}$$

$$H = -\int_{-\infty}^{\infty} \mathcal{N}(x) \log \mathcal{N}(x) dx = \frac{1+\log(2\pi\sigma^2)}{2} \tag{2.43}$$

この式から、正規分布のエントロピーは平均値 μ には全く依存せず、分散 σ^2 のみに依存して増加するという重要な性質がわかります。

まとめ

正規分布のエントロピー（不確実性）は、データの散らばり具合（分散）だけで決まる。分布の中心がどこにあるか（平均）は不確実性に影響を与えない。

例え話による解説

これは「ダーツの的の位置」と「腕前（散らばり）」の関係に似ています。的が右にあろうと左にあろうと（平均 μ の違い）、自分の投げるダーツがどれくらいバラけるか（分散 σ^2）が同じであれば、次にどこへ刺さるかの「予測の難しさ（エントロピー）」は変わりません。

2.6.3 確率分布間の「距離」（KL 情報量と交差エントロピー）

2 つの確率分布 $P(x)$ と $Q(x)$ がどれくらい離れているか（似ているか）を測る指標として、**カルバック・ライブラー（KL）情報量（KL ダイバージェンス）**が用いられます。

$$\begin{aligned} \mathrm{KL}(P||Q) &= \int_{-\infty}^{\infty} P(x) \log P(x) dx - \int_{-\infty}^{\infty} P(x) \log Q(x) dx \\ &= -H(P) + H_{PQ} \end{aligned} \tag{2.46}$$

ここで、右辺第 2 項の H_{PQ} は**交差エントロピー（クロスエントロピー）**と呼ばれ、次のように定義されます。

$$H_{PQ} = -\int_{-\infty}^{\infty} P(x) \log Q(x) dx \tag{2.47}$$

KL 情報量は、機械学習において「真の分布 P」と「モデルの予測分布 Q」のズレを最小化する（つまり交差エントロピーを最小化する）ための損失関数として極めて重要な役割を果たします。

まとめ

KL 情報量は 2 つの分布の「ズレ」を評価する指標である。真の分布と予測分布の KL 情報量を小さくすること（＝交差エントロピーの最小化）が、機械学習モデルの学習の基本原理となる。

例え話による解説

KL 情報量は「他人の価値観で生活したときのストレス度（余計なエネルギー）」です。自分本来の生活リズム（真の分布 P）があるのに、無理やり他人のルール（予測分布 Q）に当てはめて生活しようとすると、ズレが大きいほど余分な労力（KL 情報量）を消費します。自分と相手のルールが完全に一致したときに、この余分な労力（ズレ）はゼロになります。

2.7 確率分布の変数変換

2.7.1 1 変数の確率分布の変数変換

確率分布において、ある変数 x から別の変数 y への変換 $y = f(x)$ を考えます。その逆変換を $x = f^{-1}(y)$ とします。確率分布を別の変数で表現し直す際、単に元の関数に新しい変数を代入するだけでは、確率の総和が 1 になるという大前提が崩れてしまいます。そのため、変数のスケールが変わったことによる「微小な区間の伸び縮み」を補正する必要があります。

1 変数の場合、変換後の確率分布 $P(y)$ は、元の確率分布 $P(x)$ に微分の絶対値 $\left|\frac{dx}{dy}\right|$ を掛け合わせたものとして定義されます。

$$P(x)|dx| = P(y)|dy| \implies P(y) = P(x)\left|\frac{dx}{dy}\right| \tag{2.51, 2.52}$$

まとめ

確率分布の変数を変換する際、単なる関数の代入ではなく、区間の「伸び縮み」を補正するために微分係数の絶対値を掛ける必要がある。

例え話による解説

変数変換は「粘土で作った山の形を、別の定規で測り直す」ようなものです。例えば「センチメートル」の定規から「インチ」の定規に変えると、目盛りの間隔が変わります。目盛りが引き伸ばされた場所では、その分だけ粘土の高さ（確率）を低く調整しないと、全体の粘土の量（確率の合計＝ 1）が変わってしまいます。この高さの調整役を担うのが $\left|\frac{dx}{dy}\right|$ です。

2.7.2　多変数の確率分布の変数変換とヤコビアン

この考え方を、複数の変数を持つベクトル $\mathbf{y} = f(\mathbf{x})$ に拡張した場合も基本は同じです。多変数関数における空間（微小体積）の伸び縮みの割合を補正するために、偏微分を要素とする行列の行列式（ヤコビアン）を用います。

$$1 = \int P(\mathbf{x}) d\mathbf{x} = \int P(\mathbf{x}) \det \left(\frac{\partial \mathbf{x}}{\partial \mathbf{y}} \right) d\mathbf{y} = \int P(\mathbf{y}) d\mathbf{y} \tag{2.53}$$

ここで、$\frac{\partial \mathbf{x}}{\partial \mathbf{y}}$ は**ヤコビ行列（ヤコビアン）** $J(\mathbf{y})$ と呼ばれ、各変数同士の偏微分をすべてまとめた行列を指します。

$$\frac{\partial \mathbf{x}}{\partial \mathbf{y}} = \begin{pmatrix} \partial x_1/\partial y_1 & \dots & \partial x_1/\partial y_N \\ \vdots & \ddots & \vdots \\ \partial x_N/\partial y_1 & \dots & \partial x_N/\partial y_N \end{pmatrix} = J(\mathbf{y}) \tag{2.54}$$

（※ 注：確率を常に正に保つため、計算上はヤコビ行列の行列式の「絶対値」をとって補正を行います。）

まとめ

多変数の確率分布を変換する場合は、空間の体積の複雑な伸び縮みを一括で補正するために、全変数の偏微分をまとめた行列（ヤコビアン）の行列式を使用する。

例え話による解説

1 変数の変換が「直線のゴムひも」を引っ張る操作だとすれば、多変数の変換は「トランポリンの膜（2 次元）」や「ゼリーの塊（3 次元）」を縦・横・斜めに引っ張ったり歪めたりする操作です。ある場所は横に伸びて縦に縮むなど、複雑に変形します。この全体的な体積の歪み具合を計算し、全体のゼリーの量（確率の合計）が狂わないようにする「究極の補正係数」がヤコビアンです。